

# 基于深度神经网络的异源遥感 图像变化检测

作者姓名 王志锐

指导教师姓名、职称 张青富 教授

申请学位类别 工学硕士



学校代码 10701  
分 类 号 TN82

学 号 1502120821  
密 级 公开

# 西安电子科技大学

## 硕士学位论文

### 基于深度神经网络的异源遥感 图像变化检测

作者姓名：王志锐

一级学科：电子科学与技术

二级学科：电路与系统

学位类别：工学硕士

指导教师姓名、职称：张青富 教授

学 院：电子工程学院

提交日期：2018年4月



# **Change Detection for Heterogeneous Remote Sensing Images Based on Deep Neural Network**

A Thesis submitted to  
XIDIAN UNIVERSITY  
in partial fulfillment of the requirements  
for the degree of Master  
in Electronics Science and Technology

By  
Wang Zhirui  
Supervisor: Zhang Qingfu Title: Professor  
April 2018



## 西安电子科技大学 学位论文独创性（或创新性）声明

秉承学校严谨的学风和优良的科学道德，本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同事对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文若有不实之处，本人承担一切法律责任。

本人签名：\_\_\_\_\_ 日 期：\_\_\_\_\_

## 西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权属于西安电子科技大学。学校有权保留送交论文的复印件，允许查阅、借阅论文；学校可以公布论文的全部或部分内容，允许采用影印、缩印或其它复制手段保存论文。同时本人保证，结合学位论文研究成果完成的论文、发明专利等成果，署各单位为西安电子科技大学。

保密的学位论文在\_\_\_\_\_年解密后适用本授权书。

本人签名：\_\_\_\_\_ 导师签名：\_\_\_\_\_

日 期：\_\_\_\_\_ 日 期：\_\_\_\_\_





## 摘要

遥感图像变化检测是对遥感卫星拍摄的同一地点不同时刻的两幅图像进行分析,得到该地区对应时段的变化区域。异源遥感图像是利用不同传感器拍摄出的遥感图像,它们对同一种景象有着不同的表现形式。随着传感器技术的发展以及应用的需要,基于异源遥感图像的变化检测技术越来越受到关注。然而,由于异源图像在低维空间对同一地点的相同景象有着不同的表述,无法直接进行比较。本文提出利用深度神经网络提取图像的特征信息,根据特征信息得到对应的变化区域,主要包括以下三个工作:

1) 提出了基于图像邻域信息重建的异源图像变化检测方法。该方法是将其中一幅图像的邻域信息输入进深度神经网络来对另一幅图像的邻域信息重建,在两幅图像对应的变化区域会有重建误差,根据重建误差可以生成差异图,再对差异图分割处理,得到最终的变化监测结果。

2) 提出了基于差异信息学习的异源图像变化检测方法。将两幅图像的信息输入到设计的类对称的深度神经网络中,被映射到特征空间。在特征空间中,每个像素位置对应着一对特征向量,该对特征向量分别表示输入的两幅图像在该像素位置的特征信息。本文通过对特征向量的比较分析可以获取对应的差异图,对差异图进行聚类分割即可得到变化检测的结果。该方法不需要提前生成微调网络的参考图,用于调整网络参数的样本在网络更新的过程中自发选择,所以是完全无监督的。

3) 提出了基于伪标签样本学习的异源图像变化检测。该方法仍然在特征空间分析两幅异源遥感图像的差异性,但是在网络参数更新的过程中,重新设定了参与训练样本的伪标签的取值方式,最大程度上增大变化类区域与未变化类之间的差异,并且采用改进后的模糊聚类算法分割差异图,以获得更高精度的变化检测结果。

这三种方法逐步提高了异源遥感图像变化检测结果的精度。基于图像邻域信息重建的方法利用了所有像素点训练网络,生成的变化检测结果图的精度明显优于传统的后分类比较方法。基于差异信息学习的方法更新网络参数时从变化类与未变化类中同时抽选样本,并对两类样本设定了不同类型的标签值,获取的差异图的性能与变化检测的精度得到了明显的提升。基于伪标签学习的异源图像变化检测算法改进了伪标签的取值准则,进一步优化了变化检测的性能。实验结果验证了本文所提出的三种方法在异源遥感图像变化检测上的有效性。

**关键词:** 变化检测, 异源遥感图像, 深度神经网络, 邻域信息, 特征空间



## ABSTRACT

Image change detection is a process that identifies the differences between the two remote sensing images of the same area acquired at different times. With the development of application requirement, the technique for change detection based on heterogeneous remote sensing images is paid more attention. However, the detection of the differences between two heterogeneous images is very challenging, for the images shot by equipment installing different sensors have different data representation for the same true area, which results in that generating a difference image is impossible by directly comparing. In this paper, the deep neural network is utilized to extract features from the two heterogeneous images and the changed areas can be acquired by analyzing extracted features. This dissertation primarily includes the following three aspects:

1) Change detection based on local information reconstruction for heterogeneous images is proposed. One of the two images is input the deep neural network to reconstruct the local information of the other image, and then reconstruction error is used to generate the corresponding difference image. The result map can be acquired by classifying the difference image into two categories.

2) The method based on discriminative feature learning for change detection is designed for heterogeneous images. In this method, through an approximately symmetrical deep neural network the two remote sensing images are transformed into feature space, in which the difference image is generated by comparing the paired feature vectors. The changed and unchanged areas can be obtained by segmenting the difference image. The whole process does not need the reference image when the deep network is being fine-tuned and the samples are selected automatically. It is completely unsupervised.

3) The simulated labels learning is analysed for change detection based on deep neural network. The analysis of difference in the feature space is improved. In the updating of parameters, in order to enlarge the disparity between changed areas and unchanged areas the simulated labels are suitably revised. And the difference image is segmented by an improved fuzzy clustering algorithm.

These three methods gradually improve the accuracy of the change detection results for heterogeneous remote sensing images. The method based on local neighborhood information reconstruction select all the pixels for samples when training network, and the accuracy of the result is much better than the traditional postclassification comparison algorithm. The design of discriminative feature learning selects the samples from two classes, the changed and the unchanged, and sets two different type of labels for them during the fine-tuning of parameters. The performance of the difference image and the result map is improved significantly. The method based on simulated labels learning mends the value criterion of the simulated labels, and it optimizes the performance of the change detection. The experiments results demonstrate that the proposed methods achieve quite high accuracy for heterogeneous remote images.

**Keywords:** Change detection, heterogeneous remote sensing images, deep neural network, feature space

## 插图索引

图 2.1	单隐层神经网络结构 . . . . .	8
图 2.2	基于图像邻域信息重建的深度神经网络结构 . . . . .	10
图 2.3	基于图像邻域信息重建的异源图像变化检测流程图 . . . . .	11
图 2.4	S 形黄河数据集 . . . . .	13
图 2.5	PCC 算法在 S 形黄河数据集上的实验结果图 . . . . .	13
图 2.6	INIR 算法在 S 形黄河数据集上的实验结果图 . . . . .	14
图 2.7	曙光数据集 . . . . .	14
图 2.8	PCC 算法在曙光数据集上实验结果图 . . . . .	15
图 2.9	INIR 算法在曙光数据集上的实验结果图 . . . . .	15
图 3.1	RBM 结构图 . . . . .	18
图 3.2	SCCN 网络结构图 . . . . .	20
图 3.3	ASDNN 网络结构图 . . . . .	23
图 3.4	ASDBM 的结构和生成的相关的特征图 . . . . .	24
图 3.5	邻域窗口尺寸 $n$ 对变化检测结果的影响 . . . . .	28
图 3.6	ASDNN、SCCN、INIR 在 S 形黄河数据集上的生成的差异图 and 变化检测结果图 . . . . .	30
图 3.7	ASDNN、SCCN、INIR 在 S 形黄河数据集上生成的差异图对应的 ROC 曲线和 PR 曲线 . . . . .	30
图 3.8	ASDNN、SCCN、INIR 算法在 S 形黄河数据集上检测精度表现 . . . . .	31
图 3.9	ASDNN、SCCN、INIR 在 S 形黄河数据集上的差异图 and 变化检测结果图 . . . . .	32
图 3.10	ASDNN、SCCN、INIR 在曙光数据集上的 ROC 曲线和 PR 曲线 . . . . .	32
图 3.11	ASDNN、SCCN、INIR 算法在曙光数据集数据集上检测精度表现 . . . . .	33
图 3.12	Ottawa 数据集 . . . . .	34
图 3.13	MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上生成的差异图 and 变化检测结果 . . . . .	35
图 3.14	MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上的 ROC 曲线和 PR 曲线 . . . . .	35
图 3.15	MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上检测精度表现 . . . . .	36
图 3.16	裁剪的各个子集的参考图 . . . . .	37

图 3.17 ASDNN 和 SCCN 在各子集上的变化检测结果 . . . . .	38
图 3.18 ASDNN 和 SCCN 在曙光数据集及其子集上变化检测的时间和 KC 值 .	38
图 4.1 SLL 变化检测流程图 . . . . .	44
图 4.2 ASDNN 在曙光数据集各子集上的变化检测结果 . . . . .	45
图 4.3 SLL 在曙光数据集各子集上的变化检测结果 . . . . .	46

## 表格索引

表 2.1	PCC 和 INIR 在 S 形黄河数据集上的实验结果对比 . . . . .	14
表 2.2	PCC 和 INIR 在曙光数据集上的实验结果对比 . . . . .	15
表 3.1	ASDNN、SCCN、INIR 在 S 形黄河数据集上的变化检测精度对比 . .	29
表 3.2	ASDNN、SCCN、INIR 在曙光数据集上的变化检测精度对比 . . . . .	31
表 3.3	MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上变化检测的 精确度对比 . . . . .	36
表 4.1	ASDNN 和 SLL 在曙光数据集子集上变化检测的精确度对比 . . . . .	46





## 符号对照表

符号	符号名称
$\in$	集合中属于
$\Sigma$	求和
$w_{ji}$	节点 j 与节点 i 连接的权重
$h_j$	隐层第 j 个节点的值
$\cap$	集合求交集
$\partial$	求偏导
$\Delta$	变量的增量



## 缩略语对照表

缩略语	英文全称	中文对照
BP	Backpropagation	反向传播
INIR	Image Neighborhood Information Reconstruction	图像邻域信息重建
SAR	Synthetic Aperture Radar	合成孔径雷达
PCC	Postclassification comparison	后分类比较
RBM	Restricted Boltzmann Machine	受限玻尔兹曼机
ASDNN	Approximatively Symmetric Deep Neural Network	类对称深度神经网络
SCCN	Symmetric Convolutional Coupling Network	对称卷积耦合网络
FCM	fuzzy c-means	模糊c均值聚类
MR	Mean Ratio	平均比值
LR	Logarithm Ratio	对数比值
FLICM	Fuzzy Local Information C-Means	模糊局部信息c均值
DI	Difference Image	差异图
SLL	Simulated Labels Learning	伪标签学习
DAE	Denoising Autoencoder	去噪自编码器
CNN	Convolutional Neural Network	卷积神经网络



# 目录

摘要 .....	I
ABSTRACT .....	III
插图索引 .....	V
表格索引 .....	VII
符号对照表 .....	IX
缩略语对照表.....	XI
第一章 绪论 .....	1
1.1 研究背景和意义 .....	1
1.2 异源遥感图像变化检测的研究现状 .....	2
1.3 深度神经网络与变化检测 .....	3
1.4 论文的架构和内容安排 .....	5
第二章 基于图像邻域信息重建的异源图像变化检测 .....	7
2.1 反向传播算法 .....	7
2.2 用于图像邻域信息重建的方法描述 .....	9
2.3 实验 .....	12
2.3.1 变化检测评价指标 .....	12
2.3.2 实验结果及分析 .....	13
2.4 本章总结 .....	16
第三章 基于差异信息学习的异源图像变化检测.....	17
3.1 受限玻尔兹曼机的原理及应用 .....	17
3.2 SCCN 方法 .....	19
3.3 基于差异信息学习的方法描述 .....	21
3.3.1 方法的动机 .....	21
3.3.2 ASDNN 网络结构 .....	22
3.3.3 ASDNN 学习机制 .....	25
3.4 实验 .....	27
3.4.1 邻域窗口的尺寸 $n$ 的选择 .....	27
3.4.2 差异图评价标准 .....	28
3.4.3 异源遥感图像的实验结果与分析 .....	29
3.4.4 同源遥感图像的实验结果与分析 .....	33
3.4.5 ASDNN算法的时间复杂度 .....	36

3.5 本章总结 .....	39
<b>第四章 基于伪标签学习的异源图像变化检测</b> .....	<b>41</b>
4.1 基于空间信息的模糊聚类算法 .....	41
4.2 基于伪标签学习的方法描述.....	42
4.2.1 伪标签的设定 .....	42
4.2.2 SLL学习过程 .....	43
4.3 实验 .....	45
4.4 本章总结 .....	47
<b>第五章 总结与展望</b> .....	<b>49</b>
5.1 总结 .....	49
5.2 展望 .....	49
<b>参考文献</b> .....	<b>51</b>
<b>致谢</b> .....	<b>55</b>
<b>作者简介</b> .....	<b>56</b>

## 第一章 绪论

遥感图像以图像数据的形式记录着地球表面的信息，变化检测技术可以得到两幅或者多幅遥感图像之间的变化区域。随着遥感技术和变化检测技术的快速发展，人类可以实时监测地表的特征变化。现今，仅有同源遥感图像的变化检测技术已经远远不能满足应用的需求，检测出两幅异源遥感图像之间对应的变化区域具有重大的研究意义。基于此背景，本文对异源遥感图像的变化检测技术进行了深入的研究。

### 1.1 研究背景和意义

卫星传感器可以检测并记录被地球表面反射的电磁波，遥感图像作为载体来存储这类信息。近年来，各项遥感技术发展迅速，遥感图像的获取途径越来越即时便捷，遥感领域拥有着海量的图像数据以及丰富的地表信息。对遥感图像及时准确地观测和检测能够实时掌握地表特征的变化，该类信息对于人类与自然环境的和谐发展具有非常重要的意义，所以遥感图像具有重要的研究意义和应用价值。

遥感图像处理技术中不仅包含一般图像处理技术中的压缩技术、信息隐藏、图像分割，还包括能够检测地表特征变化的变化检测等技术。在遥感图像中，压缩和信息隐藏是与传输和安全相关的处理技术。卫星所拍摄的遥感图像需要传回地球被接收之后才能够得以应用，但是图像的原始数据非常庞大，图像数据必须要经过压缩才可以按照规定的流程被有效传输，所以图像压缩技术对于遥感图像的获取步骤至关重要。遥感图像不仅数据量庞大，而且价值非凡，用途也遍及各个领域，并且包含特殊的信息，比如军事信息，没有授权的人员不能使用，因此这些特殊的信息必须被隐藏。图像分割是为了得到有价值的研究目标，变化检测是为了获取地表信息的变化。图像分割和变化检测涉及遥感图像在具体领域中的应用，与人类的生活息息相关。

遥感图像的变化检测是识别出两幅非相同时的相遥感图像之间变化区域的过程。该技术可以检测出地表特征所发生的变化，一直以来都是遥感图像领域中非常具有价值的研究方向。因为国内外研究人员的精力投入，变化检测技术发展迅猛，目前应用场景非常广泛，如环境和气候监测<sup>[1][2]</sup>、城市研究<sup>[3][4][5][6]</sup>、自然灾害评估<sup>[7][8]</sup>和土地覆盖变化检测<sup>[9][10][11]</sup>等。多领域的应用需求也在进一步推动着变化检测技术的快速发展。

在遥感图像变化检测的实际应用场景中，使用计算机等机器设备自动无监督地

识别出对应的变化区域一直是变化检测技术追求的目标和发展趋势。在早期,变化的区域主要是根据图像中的像素信息和先验信息以人工描绘的方式生成,但是这样生成变化检测结果的方法不仅对人力和财力的需求量很大,而且还不能保证最终获取的结果的质量和效率。近年来,随着各种算法以及计算机各项技术的更新迭代,变化检测技术在各方面已经有了极大的发展,学术界已经研究出无监督自动生成变化检测结果的算法。遥感图像领域中的变化检测技术具备广阔研究前景和无限应用价值,目前仍需要精确度更好的方法来进一步探究遥感图像的潜在价值,以满足日益发展的切实需求。

## 1.2 异源遥感图像变化检测的研究现状

异源遥感图像在拍摄过程中利用了不同类型的传感器感应电磁波,它们对同种地表信息有着不同的像素值表达方式。随着遥感传感器技术的发展,关于异源遥感图像的研究越来越备受关注。通常情况下,异源遥感图像的变化检测流程和同源遥感图像的类似,一般包含三个步骤。一是预处理,预处理一般是指去噪和配准。去噪是去除图像中噪声的过程,遥感图像,尤其是合成孔径雷达 (SAR: synthetic aperture radar) 图像,在拍摄过程中因受自身传感器和环境因素的影响,含有大量的噪声,这些噪声会降低变化检测生成的结果的精度,去噪是必不可少的步骤。另外,两幅待检测的原始遥感图像是在不同时间拍摄的,拍摄的角度和位置会有所偏差,配准是为了将两幅图像相同的像素位置表示同一个地理坐标。二是生成差异图,差异图表示两幅遥感图像之间的像素级差异。差值算法和比值算法被广泛用于单通道同源遥感图像中。对于存在较多乘性噪声的 SAR 图像,比值算法及其变形算法大多被用于此类图像中差异图的生成。三是差异图分析。差异图分析就是将差异图二分类的过程,一类代表未变化类,另一类代表变化类。在变化检测中,差异图的生成和分析是研究的重点。

遥感图像的变化检测算法的更新周期越来越短,但是大部分的研究都是基于同源遥感图像的。同源遥感图像是利用同种或同种类型的传感器拍摄的,两幅图像对应的未变化像素的强度值是线性相关的,通过在原始图像空间直接进行像素灰度值的比较就可以生成差异图。Moser 和 Serpico 研究了 SAR 图像的变化检测,引入基于广义最小误差阈值法分割差异图,但是其检测的效果依赖于所假设的数据分布模型<sup>[12]</sup>。Gong 等人利用图像融合方法生成同源 SAR 图像的差异图,并对模糊聚类算法做了改进来分割差异图<sup>[13]</sup>。随后, Gong 等人又设计了一种基于马尔可夫能量函数的模糊聚类算法用于分析差异图<sup>[14]</sup>, Yousif 等人提出了非局部均值去噪算法用于同源遥感图像分析城市面积变化<sup>[15]</sup>等,这些研究都是基于同源遥感图像的。另外, D Lu 等人归纳总结了各类变化检测算法<sup>[16]</sup>。



异源遥感图像的信息具有互补性，但是异源遥感图像并不是由同类型传感器拍摄的，它们的数据分布不同，对同种目标信息可能有着不同的像素灰度值表示。而在遥感图像中，数据分布信息经常被用来消除噪声和图像偏移的影响。异源图像的数据信息不能直接在原始低维空间进行对比，所以对异源遥感图像的实施变化检测要比同源图像更加具有挑战性。在异源遥感图像的变化检测的研究中，光学遥感图像和 SAR 遥感图像是其主要的数据来源。光学图像的分辨率比较高，而且拍摄光学图像的传感器的覆盖面积较大，可以方便快捷地获取清晰的光学图像，但是光学传感器很容易受到光照和天气等自然环境因素的影响。SAR 图像可以实时获取，几乎不会受到上述环境因素的影响，但是它相比光学图像含有较多的噪声。所以光学图像和 SAR 图像的信息互补，获取都比较快捷，经常被用于异源遥感图像变化检测的数据来源。

异源遥感图像的变化检测非常具有挑战性，但是基于异源数据的优势也越来越受到关注，目前有许多基于异源遥感图像变化检测的研究成果<sup>[17][18][19][20][21]</sup>，但是它们其中的一些算法并不是无监督的。Mercier 等人提出了一种基于 Copula 函数的异源图像变化检测方法，该方法在获取两幅待检测图像的数据分布关联性时需要手动选取变化类的训练区域<sup>[18]</sup>。这不符合图像处理的无监督趋势。在异源遥感图像变化检测中，被普遍接受的算法是后分类比较 (PCC: postclassification comparison) 算法<sup>[21]</sup>。在 PCC 中，用同种分割算法将两幅异源遥感图像分割，分割后处于不同类别的区域被认为是对应的变化区域。但是 PCC 算法的精度依赖于分割算法的性能，对于图像中含有多种类别时的表现并不理想。所以异源遥感图像的传统变化检测算法的效果并不乐观，目前还远不能满足实际应用的需求。

模拟人脑的深度神经网络模型成为近年来重点的研究方向之一。深度神经网络通过将输入信息逐层的传递能够提取数据中的特征信息，目前已经被广泛应用于各类领域，尤其是图像处理领域<sup>[22]</sup>。对于异源遥感图像变化检测问题而言，深度神经网络的框架可以通过提取图像中的特征信息来分析两幅图像之间差异性的功能。Gong 等人提出了基于深度神经网络的字典学习的方法检测异源遥感图像之间变化的区域<sup>[22]</sup>，但是该方法需要提前生成粗略的变化检测结果用于为网络的训练提取样本和标签，并不是完全无监督的。Liu 等人提出了基于卷积的异源图像变化检测算法<sup>[23]</sup>，检测的效果相比于传统算法获得了显著的提升，但是仍有改进的空间。目前，将深度神经网络应用于异源图像变化检测是遥感领域一个重要的突破方向。

### 1.3 深度神经网络与变化检测

神经网络方面的研究已经渗透到各个学科领域，各学科对神经网络都有适应相关环境的定义。其中应用最广的神经网络定义是“神经网络是自适应简单单元组成

的广泛且并行的互连网络。它的结构可以模拟生物或者是人类大脑的神经系统对体内外现实世界的交互反应”<sup>[24]</sup>。在神经网络发展的初期，结构比较简单，一般是只含有一个隐层的单层神经网络。在神经网络中，隐层被称为功能层，但只含有一个功能层的简单神经网络结构的学习能力是十分有限的。受到人类大脑区域多分层结构的启发，含有多个隐层的交互反应能力更强的神经网络被提出。多个隐层的网络组成的就是深度神经网络，深度神经网络结构目前已经是广为流行的机器学习算法之一。

深度神经网络是多层次的非线性组合模型，能够有效地建模变量之间的复杂关系，并获得更好的泛化性能。近年来的研究为深度神经网络结构提供了很多成熟的模型，例如，受限玻尔兹曼机 (RBM: Restricted Boltzmann Machine)，去噪自编码器 (DAE: Denoising Autoencoder)，卷积神经网络 (CNN, Convolutional Neural Network) 等。理论模型的发展加快促进了深度神经网络的应用，这种深度结构已成功应用于语音、自然语言、计算生物学和图像处理等各个领域。深度神经网络可以提取图像中的细节信息和抽象信息等特征，在图像领域的应用效果非常惊人，有的甚至达到了比人眼还准确的精度，比如 faster-RCNN<sup>[25]</sup>实现了对图像中指定目标的识别和定位。遥感图像在各个领域的应用非常广泛，深度神经网络能够很好地处理图像信息，将两者相结合有着无限的研究价值。目前已经有很多研究基于深度神经网络的变化检测的方法。Liu 等人利用已有的传统变化检测算法提取样本，将差异图的邻域信息输入到深度神经网络中学习两幅遥感图像对应的变化区域<sup>[26]</sup>；Gong 等人摒弃了差异图的生成步骤，直接将两幅遥感图像的邻域信息输入到设计好的深度神经网络中，参数更新稳定后生成变化检测结果<sup>[27]</sup>。这两种算法不能应用到异源图像的变化检测中，因为它们在提取样本的过程中需要利用传统的变化检测算法，但是异源遥感图像的变化检测中还没有成熟的并且简单易操作的算法，无法向相应神经网络提供精确或粗略的样本。因此，基于深度神经网络的异源图像变化检测需要在网络学习信息的过程中自动选取样本以及生成标签。基于上述启发，基于卷积网络的异源遥感图像变化检测方法<sup>[23]</sup>可以在网络学习的过程中更新样本，实现了完全无监督的变化检测。我们也在研究过程中提出了一种新的学习差异信息的机制，在异源遥感图像变化检测精度上获得了明显的提升<sup>[28]</sup>。

异源遥感图像对同种地表特征有着不同的像素灰度值表示，两幅图像之间的差异信息不能通过在原始数据维度空间直接对比获得。但是，对于同种地表信息的不同像素灰度值数据中包含着相同的图像特征信息，而深度神经网络恰好可以提取图像中的特征信息，将深度神经网络应用于异源遥感图像变化检测的一系列研究和技术应运而生。如今，随着遥感领域中的传感器技术的迅猛发展，异源遥感图像数据的获取方式越来越快捷和丰富，存储量也越来越庞大，应用需求越来越广泛，将深

度神经网络应用于异源遥感图像的变化检测具有巨大的潜在价值。

## 1.4 论文的架构和内容安排

本文将深度神经网络与遥感领域中异源图像的变化检测结合，并把深度网络用于提取图像中的特征信息，根据特征信息获取变化检测差异图。论文提出了三种基于深度神经网络的异源遥感图像变化检测方法，总共包含五章内容，各章的主要内容如下：

第一章介绍了异源遥感图像变化检测的研究背景和意义和该问题的研究现状和难点。另外还阐述了深度神经网络的发展，以及如何将深度神经网络引用到异源遥感图像的变化检测中。

第二章提出了一种基于图像邻域信息重建的异源遥感图像变化检测方法。该方法通过深度神经网络重建遥感图像的邻域信息，根据邻域信息重建误差生成差异图，从而得到变化检测的结果。基于图像邻域信息重建的异源遥感图像检测算法通过深度神经网络提取图像的细节和抽象信息，与传统方法相比能够更加充分获取两幅图像之间的变化区域，变化检测的精度得到了显著提升。这一章介绍了神经网络训练时常用的反向传播算法、深度神经网络用于重建邻域信息的方法，并分析了实验结果。

第三章设计了基于差异信息学习的异源图像变化检测方法，它利用类对称深度神经网络将两幅异源遥感图像转化到相同的特征空间，在特征空间分析两幅图像差异信息，进而生成变化检测的结果。该方法的创新点在于从未变化类与变化类中分别抽取样本，根据选取的样本的特征设定两种类别的标签，并采取了自适应变化的学习率。这一章介绍了深度神经网络初始化所用到的受限玻尔兹曼机，然后简要分析了基于深度神经网络的 SCCN 方法的结构，接着详细描述了所提出的利用差异信息学习异源遥感图像的变化检测算法的相关细节，最后从实验的角度对多种方法进行了对比分析。

第四章提出了基于伪标签学习的异源图像变化检测方法。该方法仍然在特征空间分析两幅异源遥感图像的差异性，但是在网络参数更新的过程中，重新设定了参与训练样本的伪标签的取值方式，并且采用改进后的模糊聚类算法分割差异图。这一章介绍了改进后的模糊聚类算法，然后详细描述了伪标签的取值规则，最后根据实验结果分析所提出的方法的有效性。

最后一章归纳总结了论文的工作，对提出的三种应用于异源遥感图像变化检测的深度神经网络算法的优缺点做了总结，并在本文三种方法的基础上提出或许可行的研究建议，展望深度神经网络在异源遥感图像变化检测中进一步可能的发展。



## 第二章 基于图像邻域信息重建的异源图像变化检测

遥感图像变化检测是对遥感卫星拍摄的同一地点不同时刻的两幅图像进行对比分析而获取两幅图像对应的变化区域的过程。遥感图像变化检测分为同源图像变化检测和异源图像变化检测，同源图像是指用于拍摄遥感图像的传感器是同种类型的。大部分同源图像变化检测方法会对两幅图像先进行简单的预处理，然后直接对两幅图像实施像素级的比较获取差异图，对差异图二分类后就可以得到精确度比较好的检测结果。而异源图像异源遥感图像的变化检测与同源图像变化检测相比最大的不同是被检测的两幅遥感图像由不同的传感器拍摄的，这两幅图像对同一种景象有着不同的表现形式，因此不能直接进行像素级的比较。本章提出了一种基于图像邻域信息重建 (INIR: Image Neighborhood Information Reconstruction) 的异源遥感图像变化检测方法，利用深度神经网络重建图像邻域信息，根据重建误差获取变化检测结果。本章先介绍了所用到的神经网络中反向传播算法的相关理论知识，然后详细解析了设计的深度神经网络结构，最后对该基于图像邻域信息重建的异源图像变化检测方法进行了实验验证。

### 2.1 反向传播算法

反向传播 (BP: backpropagation) 算法是根据梯度下降原理设计的算法，可以学习神经网络中复杂的多维映射关系，是一种应用非常广泛的参数更新算法<sup>[29]</sup>。BP 曾被多次提出和改进<sup>[30][31][32][33]</sup>，成熟地引用于多种类型的网络中，目前已经发展为深度学习中的一个重要支柱。通常情况下，BP 需要和输入数据相对应的精确的标签，以一种监督的方式调整网络中的权重参数。在本文中，BP 算法需要的标签是在网络更新过程中自动生成的。

在使用 BP 算法训练神经网络之前，训练数据和标签是需要提前给定的。对于一个如图 2.1 所示的三层的神经网络，包含输入层、隐层、输出层，一旦给定样本输入，根据网络的参数可以计算网络的输出，计算公式为：

$$h_j = f(\sum_i w_{1ji} \cdot x_i + b_{1j}) \quad (2-1)$$

$$O_k = f(\sum_j w_{2kj} \cdot h_j^n + b_{2k}) \quad (2-2)$$

其中， $h_j$  表示隐层第  $j$  节点的值， $O_k$  表示输出层的第  $k$  个节点的输出值， $b_{1j}$  和  $b_{2k}$  分别表示隐层第  $j$  个节点和输出层第  $k$  个节点的偏差值， $w_{1ji}$  表示隐层的第  $j$




图 2.1 单隐层神经网络结构

个节点和输入层的第  $i$  个节点连接的权重,  $w_{2kj}$  表示输出层的第  $k$  个节点和隐层的第  $j$  个节点连接的权重,  $f(x)$  是神经网络的激活函数, 大多数情况下被设定为  $f(x) = \text{sigm}(x)$ , 其表达是为:

$$\text{sigm}(x) = \frac{1}{1 + e^{-x}} \quad (2-3)$$

$f(x) = \text{sigm}(x)$  作为激活函数的应用很广泛, 因为它的导数有一个很好的性质  $f'(x) = f(x)(1 - f(x))$ , 这个性质对于之后求取梯度有很大的优势。如图 2.1, 网络的输出和样本标签的平方误差信息可以表示为

$$E = \frac{1}{2} \sum_k (y_k - O_k)^2 \quad (2-4)$$

根据  $f(x) = \text{sigm}(x)$  导数的性质, 我们可以很方便地计算  $E$  的梯度, 而且  $E$  的梯度在网络训练过程中起着重要的作用。网络更新的目的是最小化网络输出与标准值之间的误差  $E$ 。

BP 算法是一种根据梯度下降策略研究出的算法, 它以目标函数  $E$  的负梯度方向对网络中的参数进行更新。对于图 2.1 中的网络, 如果给定学习率  $\delta$ , 那么就有

$$\Delta w_{2kj} = -\delta \frac{\partial E}{\partial w_{2kj}} \quad (2-5)$$

设定输出层第  $k$  个节点的输入  $\beta_k = \sum_{l=1}^{n2} w_{2kl} h_l$ , 那么

$$\frac{\partial E}{\partial w_{2kj}} = \frac{\partial E}{\partial O_k} \frac{\partial O_k}{\partial \beta_k} \frac{\partial \beta_k}{\partial w_{2kj}} \quad (2-6)$$



根据  $\beta_k$  的定义可知  $\frac{\partial \beta_k}{\partial w_{2kj}} = h_j$ , 由  $f'(x) = f(x)(1 - f(x))$  可以推导出

$$\begin{aligned} g_k &= -\frac{\partial E}{\partial O_k} \frac{\partial O_k}{\partial \beta_{2k}} \\ &= -(O_k - y_k) f'(\beta_k + b_{2k}) \\ &= O_k(1 - O_k)(y_k - O_k) \end{aligned} \quad (2-7)$$

将式 (2-7) 代入式 (2-6) 中, 再代入到式 (2-5) 中, 就可以得到权重  $w_{kj}^2$  的更新公式,

$$\Delta w_{2kj} = \delta g_k h_j \quad (2-8)$$

类似推导可得

$$\Delta b_{2k} = \delta g_k \quad (2-9)$$

$$\Delta w_{1ji} = \delta e_j x_i \quad (2-10)$$

$$\Delta b_{1j} = \delta e_j \quad (2-11)$$

设定  $\alpha_j = \sum_{q=1}^{n1} w_{1jq} x_q$ , 在式 (2-10) 和 (2-11) 中

$$\begin{aligned} e_j &= -\frac{\partial E}{\partial h_j} \frac{\partial h_j}{\partial \beta_{1k}} \\ &= -\sum_{l=1}^{n3} \frac{\partial E}{\partial \beta_l} \frac{\partial \beta_l}{\partial h_j} f'(\alpha_j + b_{1j}) \\ &= \sum_{l=1}^{n3} w_{2lj} g_k f'(\alpha_j + b_{1j}) \\ &= h_j(1 - h_j) \sum_{l=1}^{n3} w_{2lj} g_k \end{aligned} \quad (2-12)$$

在 BP 算法中,  $\delta \in (0, 1)$  控制着网络参数更新迭代的步长, 如果这个值太大会容易使参数优化过程产生震荡, 太小又会产生收敛速度过慢的现象, 有时候为了精细调节, 网络各层可能会设定不同的学习率<sup>[34]</sup>。大多数情况下, 网络参数初始化时会选择接近于 0 随机数, 并且为了使网络稳定及具有泛化能力, 训练时会采集大量的样本。

## 2.2 用于图像邻域信息重建的方法描述

随着传感器技术的发展以及应用的需要, 处理不同传感器拍摄的同一地区的异源遥感图像的需求越来越高, 然而异源遥感图像的数据信息不能直接在原始低维空

间进行对比，因为它们对同一地表景象在数据上有着不同的表现形式。传统的遥感图像变化检测技术主要是应用在同源图像环境下，基于异源遥感图像的变化检测传统算法通常需要经过复杂的数学模型对原始图像进行预处理，无法广泛应用于各个领域。本文提出了一种图像邻域信息重建 (INIR) 的方法实现异源遥感图像的变化检测。




图 2.2 基于图像邻域信息重建的深度学习神经网络结构

INIR 的基本思想是将其中一幅遥感图像输入到深度神经网络，重建出另一幅遥感图像所有像素点的邻域信息。理论上，在两幅图像对应的未变化区域，另一幅图像的邻域信息会被完全重构，在对应的变化区域会有重构误差，对重构误差进行分析处理就可以得到两幅异源图像对应的差异图。得到差异图之后，就可以利用普通的阈值、聚类等方法对其分类处理，获取最终的变化检测结果。这种方法不需要利用复杂的数学公式对两幅图像实施预处理操作，只要将两幅图像类似于同源图像那样配准，就可以进行重建步骤。该方法所用到的深度神经网络是全连接网络，网络的结构如图 2.2 所示。在图 2.2 中，左侧的输入图像是 SAR 图像，右侧图像是光学图像，SAR 图像和光学图像对河流景象在像素值上的表现形式就有很大的差别。从输入的 SAR 图像中提取像素点的邻域信息  $N^1_{hl}$  输入到网络中，用 BP 算法对网络训练稳定之后，重建出的光学图像对应像素的邻域信息为  $IF^1_{hl}$ ，光学图像在该像素点对应的真实的邻域信息为  $N^2_{hl}$ ，即  $IF^2_{hl}$ 。在未变化区域， $IF^1_{hl}$  和  $IF^2_{hl}$  之间的差异很小，而在变化区域，两向量之间的差异会比较大，因此，我们定义

$$DI(h, l) = \|IF_1(h, l) - IF_2(h, l)\|_2$$

$$s.t. (1 \leq h \leq H, 1 \leq l \leq L) \quad (2-13)$$

其中  $H$  和  $L$  分别对应图像的高和宽。获取的差异图  $DI$  后，对其进行二分类处理，可得到对应的二值图，即异源图像变化检测的结果。



深度神经网络相比于简单的单隐层神经网络的优势在于可以更好地映射非线性关系，提取图像数据的特征信息。但是由于激活函数  $f(x) = \text{sigm}(x)$  和 BP 算法的局限性，隐层数目过多之后，深度神经网络的更新迭代会出现梯度弥散现象，造成目标函数  $E$  的值不能收敛。为了达到更好映射非线性关系和避免梯度弥散现象两者的折衷，本文中的深度神经网络都选取了 5 层的结构，即包含 3 个隐层，各层的具体节点数为  $n \times n \times c1 - 100 - 75 - 50 - n \times n \times c2$ ，其中  $n$  表示邻域窗口的大小， $c1$  和  $c2$  分别表示输入图像和被重建邻域信息图像的通道数。在实际图像应用中，网络隐层的节点数如果过多，会增加计算复杂度，使网络更新速度缓慢，其实只要这些节点数目不是过小，那么它们对变化检测结果的影响都不大，甚至可以忽略。将基于图像邻域信息重建的深度神经网络结构用于异源图像变化检测时，权重参数和偏差参数是随机初始化的，并且  $\delta = 0.2$ ，整个变化检测过程的流程图如图 2.2 所示




图 2.3 基于图像邻域信息重建的异源图像变化检测流程图

INIR 是一种基于深度神经网络的简单易操作的异源遥感图像变化检测方法，它不需要经过复杂的数学模型对图像进行转换等预处理操作，而且整个过程不需要任何的先验信息，是完全无监督的。该方法对异源图像变化检测有很大的启发，本文之后研究出的两种基于深度神经网络的异源遥感图像变化检测方法都是在此基础上进行的。

## 2.3 实验

实验选取了两组异源图像数据集对所提出的 INIR 算法进行分析和验证，各项参数的设定和第 2.2 节中相同。该部分首先介绍了变化检测的评价指标，然后用评价指标对所提出的方法在两组图像数据集上量化分析并综合评价。

### 2.3.1 变化检测评价指标

两幅异源遥感图像变化检测的结果是以一幅二值图的形式展现。在这幅二值图中，白色像素区域代表变化的区域，黑色代表未变化的。为了更好地评价一种变化检测方法的性能，需要一些定量和定性的指标来分析变化检测的结果。在变化检测中定义的指标有<sup>[35][36]</sup>：真正数 (TP: True Positive) 表示参考图中为正，实际的变化检测结果图中为正的像素点个数；真负数 (TN: True Negative) 表示参考图中为负，实际的变化检测结果图中为负的像素点个数；假正数 (FP: False Positive) 表示参考图中为正，实际的变化检测结果图中为负的像素点个数；假负数 (FN: False Negative) 表示参考图中为负，实际的变化检测结果图中为正的像素点个数。由上述基本评价参数衍生的评价标准有：真正率 (TPR: True Positive Rate)，真正数与参考图中所有为正像素点个数的比值， $TPR = TP / (TP+FP)$ ；真负率 (TNR: True Negative Rate)，真负数与参考图中所有为负像素点个数的比值， $TNR = TN / (TN+FN)$ ；错检率 (OE: Overall Error)，被检测错误的像素点个数与参考图或者结果图所有像素点个数的比值， $OE = (FN+FP) / (TP+TN+FP+FN)$ ；分类精度 (CA: Classification Accuracy)，被检测正确的像素点个数与参考图或者结果图所有像素点个数的比值， $CA = (TP+TN) / (TP+TN+FP+FN)$ 。以及根据上述各项指标计算综合评价变化检测结果的 Kappa 系数 (KC: Kappa Coefficient)，

$$KC = \frac{CA - PRE}{1 - PRE} \quad (2-14)$$

其中，

$$PRE = \frac{(TP+FP)(TP+FN)}{(TP+TN+FP+FN)^2} + \frac{(FN+TN)(FP+TN)}{(TP+TN+FP+FN)^2} \quad (2-15)$$

KC 是一种一致性评估指标，对变化检测方法的评价有着很重要的参考意义。

为了保证实验结果的客观性以及避免随机参数的影响，所有的评价指标都是取的 30 次重复试验的平均值。

### 2.3.2 实验结果及分析

随着传感器技术的发展，异源遥感图像的处理技术需求越来越大，基于传统方法的异源图像变化检测也取得了很大的进步，其中应用最广泛的是 PCC 算法。PCC 是一种基于图像分割的算法，它的原理是先将两幅图像分别分割，变化检测结果的二值图是通过比较两幅分割结果图来生成的。两幅图像中处于不同类别的区域在二值图中被划分为变化的区域，处于相同类别的区域被划分未变化的区域。这种方法简单快捷且易于理解，检测过程中不需要生成差异图，但是它的效果依赖于分割算法的性能，并且容易受图片本身质量的影响。本章选取了两组异源遥感图像数据集用作实验分析，将 INIR 算法和 PCC 算法对比。

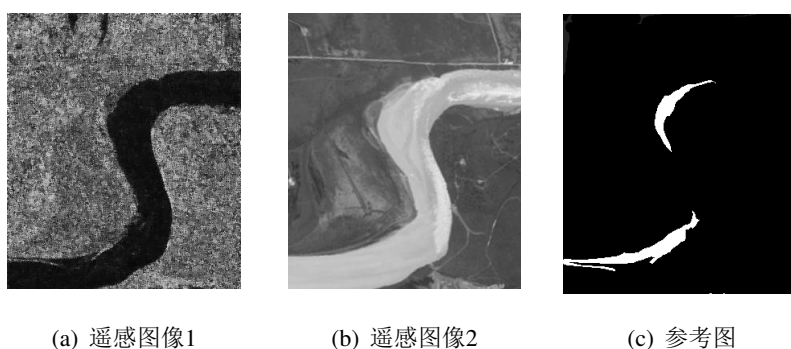


图 2.4 S 形黄河数据集





图 2.5 PCC 算法在 S 形黄河数据集上的实验结果图

INIR 和 PCC 算法在 S 形黄河数据集上的实验分析。如图 2.4 所示，数据集中三幅图像的大小是  $291 \times 343$ ，分辨率相同。图 2.4(a) 是一幅 SAR 图像，拍摄于 2008 年 6 月；图 2.4(b) 是一幅光学图像，拍摄于 1996 年 7 月；图 2.4(c) 是变化检测结果的参考图，它是根据图 2.4(a) 和图 2.4(b) 的像素灰度值特征以及先验信息手动描绘的。



(a) 差异图


(b) 变化检测结果图

图 2.6 INIR 算法在 S 形黄河数据集上的实验结果图

表 2.1 PCC 和 INIR 在 S 形黄河数据集上的实验结果对比

评价指标 算法	OE	CA	KC
PCC	0.0389	0.9611	0.5064
INIR	0.0309	0.9691	0.5074

将 INIR 算法和 PCC 算法应用于 S 形黄河数据集上，实验结果如图 2.5 和图 2.6 所示。因为该数据集中的两幅异源图像只包含两类景象（河流和土地），PCC 算法在该数据集上也取得了不错的效果，但是对比图 2.5(c) 和图 2.6(b) 可以发现，图 2.6(b) 中的噪声相对明显较少，所以 INIR 算法的结果对噪声更具有鲁棒性。表 2.1 中给出了 INIR 和 PCC 两种算法实验结果的各项评价指标值，INIR 在 OE、CA 和 KC 三项指标中均优于 PCC 算法，说明本章提出的 INIR 算法对异源遥感图像的变化检测是有效的，且优于传统的算法。



(a) 遥感图像1

(b) 遥感图像2

(c) 参考图

图 2.7 曙光数据集

INIR 和 PCC 算法在曙光数据集上的实验分析。如图 2.7 所示，数据集中三幅图像的大小是  $921 \times 593$ ，分辨率相同。图 2.7(a) 是一幅 SAR 图像，拍摄于 2008 年 6 月；图 2.7(b) 是一幅光学图像，拍摄于 2013 年 9 月；图 2.7(c) 是变化检测结果的参考图，它是根据图 2.7(a) 和图 2.7(b) 的像素灰度值特征以及先验信息手动描绘的。在曙光数据集上，INIR 算法的性能明显优于 PCC 算法，和参考图相比，INIR 算法




图 2.8 PCC 算法在曙光数据集上实验结果图




图 2.9 INIR 算法在曙光数据集上的实验结果图

表 2.2 PCC 和 INIR 在曙光数据集上的实验结果对比

评价指标 算法	OE	CA	KC
PCC	0.1790	0.8210	0.2569
INIR	0.0616	0.9384	0.5049

获得了很好的变化检测结果，而 PCC 算法的结果图中有很多与实际不相符的变化区域。PCC 算法将图像 2.7(a) 分割成了两类，将图像 2.7(b) 分割成了三类，通过观察可以看出图像 2.7(a) 也包含三类景象，但是分割算法没有将其正确分割，这直接导致了最后变化检测结果精确度的下降。但是 INIR 是基于深度神经网络的算法，它可以学习到图像当中更多的细节和抽象特征，只要两幅遥感图像对应区域所表示的景象相同，其中一幅图像就可以重建出与另一幅图像相近的邻域信息。两种方法在评价指标上的定量对比结果见表 2.2，在 KC 评价指标和其他评价指标中，INIR 算法都有极大的优势。

实验选取了 S 形黄河数据集和曙光数据集对 INIR 算法和 PCC 算法进行了对比分析，在两组数据集实验中，INIR 算法都表现出了其相对于 PCC 算法的优势。尤其在曙光数据集中，INIR 算法获得了非常好的变化检测结果，表现出了神经网络应用在异源图像变化检测领域的前景。因为深度神经网络可以学习到图像数据中的细节和抽象信息，只要两幅遥感图像对应区域所表示的景象相同，其中一幅图像就可

以重建出与另一幅图像相近的邻域信息，以 INIR 算法的变化检测结果不会受到图像中景象类别复杂度的影响，在 S 形黄河数据集和曙光数据集上都取得了很好的效果。总体来说，INIR 算法能够成功应用于异源遥感图像的变化检测中。

## 2.4 本章总结

本章提出了一种基于图像邻域信息重建 (INIR) 的异源图像变化检测算法。该算法利用深度神经网络，以其中一幅图像作为输入，重建出另一幅图像的邻域信息，通过分析重建误差生成差异图，然后对差异图进行二分类获取变化检测的结果。

本章介绍了与深度神经网络相关的理论知识和 INIR 算法的网络结构，以及变化检测方法的性能评价指标，然后在两组数据集上对 INIR 算法和传统算法 (PCC) 做了对比分析。通过观察实验结果可以看出，PCC 算法的变化检测结果容易受到分割算法性能的影响，而 INIR 算法的结果表现出了深度神经网络应用于异源遥感图像变化检测中的优势，这得益于在重建图像邻域信息时，网络结构可以学习到更多的细节和抽象信息。但是观察 INIR 算法生成的差异图，可以发现差异图中变化区域与非变化区域的差别不是很明显，文章之后会对这点加以改进。总之，这种基于深度神经网络的图像邻域信息重建的变化检测算法相比于传统的算法更适用于异源遥感图像。

### 第三章 基于差异信息学习的异源图像变化检测

在异源遥感图像的变化检测，被用于检测的两幅遥感图像由不同的传感器拍摄的，这两幅图像对同一种地表景象有着不同的表现形式，因此不能在原始数据的低维空间直接进行像素级的比较。而深度神经网络可以提取图像中的细节和抽象信息，让异源图像的变化检测任务在特征空间空间中实施，在该领域有着非常好的应用前景，很多研究者投入到了基于深度神经网络的图像变换检测中，其中能很好应用于异源图像的是 Liu 等人所提出的基于卷积的 SCCN 方法<sup>[23]</sup>。在第二章中，本文提出了一种基于图像邻域信息重建的异源图像变化检测，该方法相对于传统方法取得了很好的检测效果，但是该方法的不足之处是生成的差异图中变化区域和未变化区域的像素值差异不明显，这应该和样本的选取有关。针对上一方法的不足，本文提出了一种基于差异信息学习的异源图像变化检测算法，该方法利用类对称网络 (ASDNN: approximatively symmetric deep neural network) 将图像转化的相同的特征空间，在特征空间分析差异信息，从而得到变化检测结果。根据该方法中所使用的特殊的网络结构，我们将其简称为 ASDNN。ASDNN 从变化类和未变化类两类区域中分别选取样本，并采用了独特的标签值设定方式以及自适应变化的学习率迭代更新网络参数。本章主要介绍了深度神经网络初始化所用到的受限玻尔兹曼机，基于深度神经网络的 SCCN 方法，本文提出的 ASDNN 算法的相关细节和多种方法的实验结果对比与分析。

#### 3.1 受限玻尔兹曼机的原理及应用

RBM 是一种基于能量模型的生成式神经网络结构，最开始被 Smolensky 以 Harmony 理论的形式提出<sup>[37]</sup>，后来其训练方法由 Hinton 进行了改进<sup>[38][39]</sup>，被广泛应用于分类<sup>[40]</sup>、滤波<sup>[41]</sup>、特征学习<sup>[42]</sup>等。

RBM 包含可视层和隐含层两层结构，如图 3.1 所示。在图 3.1 中，可视层  $V = \{v_1, v_2, \dots, v_n\}$  有  $n$  个节点，隐含层  $H = \{h_1, h_2, \dots, h_m\}$  有  $m$  个节点。RBM 的结构最重要的特征是层间节点全连接，层内节点无连接。每一个可视层的节点都和所有的隐含层的节点相连，但是可视层的节点之间是没有连接的，所以可视层节点的取值只受限于隐含层节点。类似地，隐含层节点的取值也只受限于可视层节点。在 RBM 中，除了节点的值之外，还有一些用于训练网络模型的参数，如图 3.1 中可视层的偏差向量  $V_b = \{v_{b1}, v_{b2}, \dots, v_{bn}\}$ ，隐含层的偏差向量  $H_b = \{h_{b1}, h_{b2}, \dots, h_{bm}\}$ ，以及连接可视层和隐含层的权重向量






图 3.1 RBM 结构图

$w = \{w_{i,j} | 1 \leq i \leq n, 1 \leq j \leq m\}$ 。这些参数的值定义了  $n$  维的数据怎么由  $m$  维的数据来表示的。图 3.1 所示的 RBM 结构模型对应的能量关系为：

$$E(V, H) = - \sum_{i=1}^n v_{bi} \cdot v_i - \sum_{j=1}^m h_{bj} h_j - \sum_{i,j} v_i h_j w_{i,j} \quad (3-1)$$

根据 3-1 可以得到可见层向量和隐含层向量的联合概率分布为：

$$p(V, H) = \frac{1}{Z} e^{-E(V, H)} \quad (3-2)$$

其中  $Z$  为归一化因子，

$$Z = \sum_{V, H} e^{-E(V, H)} \quad (3-3)$$

当隐含层向量  $H$  给定时，可见层向量  $V$  的取值便可随之确定，

$$p(V) = \frac{1}{Z} \sum_H e^{-E(V, H)} \quad (3-4)$$

同理，当可见层向量  $V$  给定时，隐含层向量  $H$  也可确定，

$$p(H) = \frac{1}{Z} \sum_V e^{-E(V, H)} \quad (3-5)$$

上述公式中  $Z$  的计算复杂度非常高，无法直接计算。Hinton 等人利用数学公式的推导简化了各项参数的更新<sup>[43]</sup>。简化后，权值向量  $w$  的更新公式为：

$$\Delta w_{ij} = \delta (\langle v_i \cdot h_j \rangle_{data} - \langle v_i \cdot h_j \rangle_{re}) \quad (3-6)$$

其中  $\delta$  为学习率，角括号表示在当前分布下的期望， $\langle \cdot \rangle_{re}$  表示模型生成的数据分布。在给定可见层向量  $V$  时，隐含层节点  $h_j$  被激活的概率为：

$$p(h_j = 1 | V) = \text{sigm}(h_{bj} + \sum_{i=1}^n v_i \cdot w_{ij}) \quad (3-7)$$



同时，在给定隐含层向量  $H$  时，可见层节点  $v_i$  被激活的概率为：

$$p(v_i = 1|H) = \text{sigm}(v_{bi} + \sum_{j=1}^m h_j \cdot w_{ij}) \quad (3-8)$$

上述公式中， $\text{sigm}(x) = \frac{1}{1+\exp(-x)}$  表示激活函数。在 **RBM** 的训练中，首先由输入数据确定可见层向量  $V$ ，根据公式 (3-7) 计算隐含层向量  $H$  的值， $H$  确定后，再根据公式 (3-8) 计算 **RBM** 重建的可见层向量  $V$  的值。所需要的数据的值都被确定之后，由公式 (3-6) 便可计算  $\Delta w$ 。如此反复更新 **RBM** 模型中的参数，直到符合收敛的条件。

因为 **RBM** 的训练时不需要提前设置任何标签，避免了很多预处理操作，是一种完全无监督的网络模型，所以它的应用非常广泛。在 **RBM** 模型中，可见层和隐含层实际上是输入数据信息的两种不同的表达形式，所以我们可以根据需要将输入映射到不同的特征空间分析数据的特征，比如图像压缩。**RBM** 用于图像分析时，图像中像素的灰度值被归一化到 0 和 1 之间，表示对应的神经元被激活的概率。此外，**RBM** 还可以作为生成式模型<sup>[38]</sup>和分类模型<sup>[44]</sup>。深度神经网络的随机初始化会使结果有一定的不稳定性，将多个 **RBM** 堆叠生成多层的受限玻尔兹曼机 (**RBM**s: **Restricted Boltzmann Machines**) 来对网络进行初始化会使其更加鲁棒。在 **RBM**s 中，当前的 **RBM** 的输出是与之相连的下一个 **RBM** 的输入。在本文中，**RBM** 用于初始化深度神经网络，无监督地提取和学习图像信息。

### 3.2 SCCN 方法

基于深度卷积网络的 **SCCN** 方法是一种异源图像变化检测算法，**SCCN** 的网络结构如图 3.2 所示。**SCCN** 的深度神经网络是一种对称的结构，两边的输入分别连接着用于变化检测的两幅遥感图像，构成其结构框架的两个子网络都包含一个卷积层和若干个全连接层，在全连接层中，所有像素点共享卷积权重参数， $W_1$  是第一层的卷积权重。**SCCN** 的目的是生成与两幅遥感图像对应的差异图，所以在卷基层操作中没有引入池化步骤。在经过卷基层和若干全连接层的传播后，两幅图像就被转化到了特征空间。在特征空间，两幅图像对于同一种地表景象相比于低维空间有着更相似的表达方式，并且每一个像素都会对应着一个特征向量，那么差异图就可以通过对比向量对之间的差异来获取，在 **SCCN** 中采取的是欧氏距离的度量方法， $DI(x, y) = \|H_1(x, y) - H_2(x, y)\|_2$ 。

**SCCN** 算法也是一种无监督的异源图像变化检测算法，不需要任何的先验信息，输入两幅配准的遥感图像，它就可以输出对应的差异图。用于引导网络迭代的目标

函数为

$$\begin{aligned}
 \min F_{cop}(\theta, P_u) = & \sum_{(x,y)} P_u(x,y) \|H_1(x,y) - H_2(x,y)\|_2 \\
 & - \lambda \sum_{(x,y)} P_u(x,y) \\
 s.t. & 0 \leq P_u(x,y) \leq 1
 \end{aligned} \tag{3-9}$$

其中  $\theta$  表示网络中的参数,  $P_u(x,y)$  像素点  $(x,y)$  属于未变化类的概率, 向量对  $H_1(x,y)$  和  $H_2(x,y)$  是两幅图像在像素点  $(x,y)$  处对应的特征向量对,  $\lambda$  手动定义的一个权重参数。在深度神经网络 SCCN 的迭代学习过程中, 当式 (3-9) 中  $F_{cop}$  的值不在变化时, 就停止迭代,  $\lambda$  和  $P_u(x,y)$  是选取样本相关的两个重要参数。

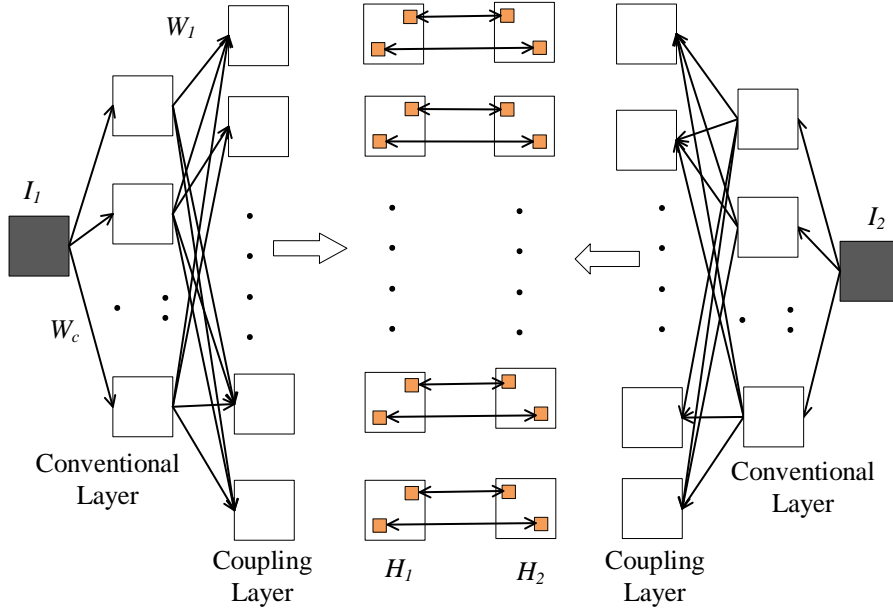


图 3.2 SCCN 网络结构图

SCCN 是一种用于异源图像变化检测的简单并且有效的算法, 它考虑到了变化区域不能像未变化区域那样映射到特征空间, 利用一种类对称的深度学习神经网络生成差异图, 可同时应用于异源和同源图像的变化检测任务中。与以往基于深度神经网络的变化检测算法不同的是, SCCN 算法是无监督的, 不需要提前生成简略的结果图以提取样本, 供给网络参数更新的样本是在训练的过程中按照一定的规则自动选取的。在网络迭代的过程中, SCCN 每次选取根据  $\lambda$  和  $P_u$  判定的属于未变化类的像素点作为样本参加训练, 但是没有对属于变化类的像素点采取任何操作, Liu 等人在文献也提出它适用于变化区域明显小于未变化区域的场景。SCCN 仍然可能会有与 INIR 类似的问题, 差异图中变化区域与非变化区域的差别不是很明显, 只是程度可能略轻。

因此，急需一种对变化区域与未变化区域综合考虑的基于深度神经网络的异源图像变化检测算法。

### 3.3 基于差异信息学习的方法描述

基于差异信息学习的深度神经网络是一种类对称的网络 (ASDNN)，它将用于变化检测的两幅异源遥感图像转化到同一特征空间，在特征空间分析两幅图像之间的差异，从而生成差异图。在特征空间，来自两幅图像的每一个像素位置都有对应的特征向量对，特征向量对对同一地表景象内容的表达会很相近，对不同地表景象内容的表达会有一定的差异。每对向量对之间的差异就是 ASDNN 生成差异图的依据。ASDNN 网络是利用 RBMs 初始化的，RBMs 初始化网络的同时也是初步提取图像信息的过程，论文将详细介绍方法的细节。

#### 3.3.1 方法的动机 研究动机?

异源遥感图像在拍摄的过程中使用了不同类型的传感器，所以变化检测不能像同源遥感图像那样在低维空间直接进行像素值的比较，而传统的基于复杂数学公式推导的方法不易理解，而且难于实施。深度神经网络可以通过非线性映射的方法提取图像中细节和抽象信息，是一种很好的能够应用于异源遥感图像的结构。本文第二章提出了利用深度神经网络重建图像邻域信息的异源图像变化检测方法 INIR，这种方法利用其中一幅图像输入到深度神经网络来重建另一幅图像的邻域信息，通过分析重建误差来生成差异图。通过实验分析，我们可以看到它相对于传统的算法有很大的优势，在实验上取得了很好的效果。但是这种方法所生成的差异图对变化区域和未变化区域的差异性表示的不够明显。本章的上一小结中介绍了一种基于卷积神经网络的异源图像变换检测算法 SCCN，该方法考虑到了变化的区域不能够像未变化区域那样不做任何处理就用于训练网络的样本，所以它选择了舍弃了这部分样本，理论上这样的处理方式应用的前提是两幅异源遥感图像对应的变化的区域要明显少于未变化的区域，Liu 等人也提出了这一点<sup>[23]</sup>。SCCN 相比于 INIR 算法在变化检测效果上有所改进，但是仍然没有彻底解决差异图对变化区域和未变化区域的差异性表示的不够明显这个问题。

深度神经网络作为一种模拟人脑结构的模型，可以很好的描述输入和输出之间复杂的非线性映射关系。深度神经网络的这个特征也提醒了我们可以利用这种结构将用于变化检测的异源遥感图像转化到特征空间，在特征空间，表示同一种景象的特征向量会有极小的差异，当然这种效果也需要一种适用的学习机制来达到。针对于上述两种方法的不足之处，在本章中我们设计了一种基于差异信息学习的深度神经网络结构 ASDNN 和一种全新的深度神经网络学习方式。ASDNN 是一种类对称的

全连接深度神经网络结构，两个输入端口分别连接着两幅配准的异源遥感图像。经过 ASDNN 结构，两幅异源遥感图像被转化到特征空间，我们在特征空间分析对应的特征向量来生成差异图。ASDNN 在更新网络参数的过程中，不仅在未变化的区域抽选样本，也在变化的区域抽选样本。全新的训练方式的目的是缩小未变化区域对应的特征向量对之间的差异，同时扩大变化区域对应的特征向量对之间的距离。训练稳定后的 ASDNN 就能够生成更加符合要求的差异图。

ASDNN 是一种全连接的类对称网络结构，并没有使用被普遍认为适用于图像处理的卷积层，这是因为浅层的卷积网络无法体现其优势，而且深度的卷积网络的感受野很大，需要巨大量的样本来训练网络，目前并不适用于本文的图像变化检测任务。卷积网络是一种很好的结构，但是它更适用于需要图像全局信息的图像识别或分类，在深度学习中被熟知的 yolov<sup>[45]</sup>、faster-RCNN<sup>[25]</sup>、ResNet<sup>[46]</sup> 等都是很深层次的卷积网络结构，且被用于图像中的目标识别和定位。如果要处理遥感图像中的目标识别或跟踪任务，深度卷积结果是一种非常好的结构。通过观察图 3.2，我们可以发现，SCCN 虽然是以基于卷积网络的方式提出，但是网络结构中只包含一层的卷积，这个跟前面所说的卷积网络的感受野与遥感图像变化检测问题本身的特点有关系。卷积的层数越多，最后一层网络特征图中一个像素点的感知野越大，然而，对于变化检测研究而言，不需要很大的感知野，因为感知野越大，会带来更多的不确定性，不利于检测出变化的区域，所以卷基层增多反而不利于该问题的解决。但是，只用一层的卷积网络，和全部都用全连接的结构相比并没有明显的优势。所以，ASDNN 的设计采用了全连接网络的结构。

### 3.3.2 ASDNN 网络结构

ASDNN 网络是一种类对称的网络结构，ASDNN 的主要目的是将两幅用于变化检测的遥感图像映射到同一特征空间，在特征空间中对比两幅图像之间的差异，从而生成差异图。在 ASDNN 中，两幅图像分别输入到两边的网络中，每一层网络输出是与其相连的下一层网络的输入，以 S 形黄河数据集中的异源遥感图像分别作为  $I_1$  和  $I_2$  为例，具体的结构如图 3.3 所示。 $N_{hl}^1$  和  $N_{hl}^2$  分别是  $I_1$  和  $I_2$  在像素位置  $(h, l)$  的邻域信息，邻域窗口大小为  $n$ ， $f_1$  和  $f_2$  分别是两幅图像对应的映射函数。ASDNN 训练稳定后， $f_1$  和  $f_2$  就是与权重 ( $W = W_1^1, W_1^2, W_2^1, W_2^2, \dots, W_N^1, W_N^2$ ) 相关的函数，具体的表达式没有必要知道，我们只需要根据深度神经网络的结构计算出对应的特征向量即可。那么，差异图的计算方式为

$$\begin{aligned} DI(h, l) &= \|f_1(h, l) - f_2(h, l)\|_2 \\ s.t. &(1 \leq h \leq H, 1 \leq l \leq L) \end{aligned} \quad (3-10)$$




图 3.3 ASDNN 网络结构图

$H$  和  $L$  的含义与式 (3-10) 中的含义相同。ASDNN 仍然采用了层数为 5 的结构，每一边相关层数的节点数为  $n \times n \times c1 - 100 - 75 - 50 - n \times n \times c2$ ，其中  $x$  表示对应输入端口所输入图像的通道数。这种结构看似和 SCCN 很相像，但是在训练过程中采用了不同的学习机制，而且选取样本的方式也是不同的。ASDNN 所生成的差异图对变化区域和未变化区域的差异性表示得相对更加明显。

ASDNN 引用 RBMs 结构来对网络参数进行初始化，摒弃了随机初始化的方式，这使得网络更具有稳定性。RBM 是一种生成式概率模型，其结构中的隐含层和可见层其实是输入信息的两种不同的表达方式，因为它训练的过程中不需要标签，被广泛应用于无监督提取特征以及初始化其他模型的网络。多个 RBM 堆叠，即当前 RBM 的输出是与之相连的下一个 RBM 的输入，是一种多层受限玻尔兹曼机 (RBMs)。为了初始化 ASDNN，我们设计了一种类对称的深度受限玻尔兹曼机 (ASDBM: approximately symmetric deep RBM)，ASDBM 的两边都是 RBMs 结构。ASDBM 可以先初步提取图像中的信息，生成初始的特征向量和特征图，结构和特征图如图 3.4 所示。

ASDBM 的训练就是多个 RBM 的训练，它的初始化方式仍然是随机初始化，但是训练稳定后的 ASDBM 不会受到随机因素的影响。从图像中提取的邻域信息被转化一维向量，作为首个 RBM 的可视层输入到 ASDBM 中。ASDBM 是多个 RBM 堆叠形成的网络，由图 3.4 可以观察到，一个 RBM 的隐含层是与其相接的下一个 RBM 的可视层，如此传递直到最后一个 RBM，图像的信息也随之传递到网络的输出层。网络的层数越深，通过训练得到的图像的信息越纯净，从两幅图像的邻域信息转化而来的特征向量对于同种地表景象特征在数值上的表达方式越相近。但是神经网络的隐含层数目太多，会有梯度弥散的现象，不利于网络的训练和特征的提取，所以网络层数的选择参考了 INIR 的设计，仍然设定为 5。因为在构建网络的过程中，将固定窗口大小的邻域信息输入到网络中，而且是在特征空间中分析两幅图像的差



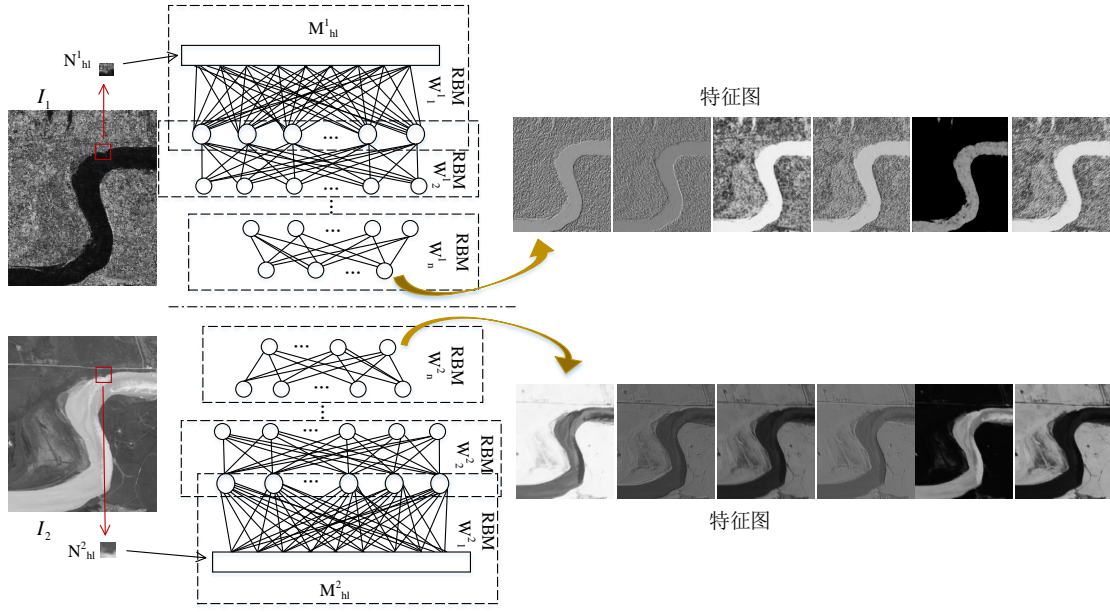


图 3.4 ASDBM 的结构和生成的相关的特征图

异性，所以邻域窗口的大小可能会影响到最后的变化检测结果，关于邻域窗口大小  $n$  的选取会在之后的实验部分分析。在 INIR 方法中，并没有对  $n$  的选取展开分析，原因是在基于重建的网络中，最终的目的还是在图像原本的维度空间分析差异性，提取的细节信息和抽象信息并没有直接用于分析差异性， $n$  的选取并不会造成重大影响。ASDBM 训练稳定之后，就可以生成与输入图像相对应的特征图，用于初步差异性的分析。

ASDBM 训练完成后，将权重设置成单向的并且指向输出端，就是初始化好的 ASDNN 网络。ASDNN 是一种类对称的深度神经网络结构，它从遥感图像中抽选符合条件的样本，对参数迭代更新。它在参数更新过程中采取了全新的样本选择策略和自适应变化的学习率。ASDNN 采用一种全新的样本选取策略，它从变化类和未变化类两类中按照一定的规则选取样本，并设定对应的两类样本的标签值，目的是使生成的差异图对变化区域和未变化区域之间的差异性有更明显的表达。训练过程中学习率并没有被设定成固定的值，而是根据正用于训练的样本本身的特点自适应选择大小。具体的细节在后面会有与之相关的详述。将两幅图像重新输入训练稳定后的 ASDNN 中，两幅异源遥感图像就会被映射到相同的特征空间，在特征空间中它们对于相同的地表景象有着非常近似的向量表示，而对于不同的地表景象有着差异性的向量表示，这个差异性已足以将变化类与未变化类区分开。对两幅图像在特征空间中进行差异性分析，就可以生成对应的差异图，差异图二分类后就能够得到变化检测的结果。

### 3.3.3 ASDNN 学习机制

ASDNN 主要的创新与贡献有三点，定义了一个新的目标函数，引入了自适应变化的学习率，以及采用了全新的样本选择策略。ASDNN 根据网络的特点和自身要解决的问题，提出了更符合生成差异图要求的目标函数。ASDNN 在训练过程中并没有将学习率设定为固定值，而是根据正在用于训练的样本对于变化类或非变化类的隶属度来自适应确定取值。另外，与以往基于深度神经网络的异源图像变化检测方法只在未变化类中选取样本或者把所有像素都作为样本不同的是，ASDNN 按照一定的规则从变化与未变化两类中选取符合要求的样本。

首先，ASDNN 定义了一个新的目标函数。ASDNN 是一种类对称的深度神经网络，特征向量都是成对出现的。假设像素点  $(h, l)$  是两幅图像  $I_1$  和  $I_2$  的一个像素位置，那么两幅图像在该点处的邻域信息通过 ASDNN 的传播映射到特征空间的特征向量分别为  $f_1(h, l)$  和  $f_2(h, l)$ 。当  $(h, l)$  属于未变化类时，网络要尽量缩小  $f_1(h, l)$  和  $f_2(h, l)$  之间的距离，当  $(h, l)$  属于变化类时，网络要尽量使  $f_1(h, l)$  和  $f_2(h, l)$  之间的距离增大。所以 ASDNN 的目标函数被定义为

$$\begin{aligned}
 Q(\theta) &= \sum_{h,l} F(h, l) \\
 &= \frac{1}{2} \frac{1}{\sum_{h,l} (S_1) + \sum_{h,l} (S_2)} \sum_{h,l} (S_1(h, l) \|f_1(h, l) - f_2(h, l)\|_2 \\
 &\quad + S_2(h, l) \|f_1(h, l) - f_{22}(h, l)\|_2) \\
 &\quad s.t. (1 \leq h \leq H, 1 \leq l \leq L)
 \end{aligned} \tag{3-11}$$

其中  $\theta = \{W, b\}$  代表 ASDNN 中的网络参数，函数  $f_{22}$  的引入是为了扩大  $f_1(h, l)$  和  $f_2(h, l)$  之间的距离，它的定义方式为

$$f_{22j}(h, l) = \begin{cases} f_{2j}(h, l) - 0.5 & f_2(h, l) \geq 0.5 \\ f_{2j}(h, l) + 0.5 & else \end{cases} \tag{3-12}$$

$f_{2j}(h, l)$  是特征向量  $f_2(h, l)$  中第  $j$  个节点的值。在 ASDNN 训练的过程中，我们将左半边的网络视为训练网络，右半边的网络视为标签网络，分别对应着 ASDBM 的上半网络和下半网络。 $f_2$  对应着标签网络的映射函数，当 ASDBM 训练结束即 ASDNN 的初始化完成后， $f_2$  就不再变化，随之  $f_{22}$  也被确定，那么  $f_2(h, l)$  和  $f_{22}(h, l)$  就是像素点  $(h, l)$  分别隶属于未变化类与变化类情况下参与训练时的两种标签。差异图  $DI$  表示用于变化检测的两幅遥感图像  $I_1$  和  $I_2$  之间在对应像素点的差异程度，所以当  $(h, l)$  属于变化类时，向量  $f_1(h, l)$  和  $f_2(h, l)$  之间的距离要足够大， $(h, l)$  对应的标签与  $f_2(h, l)$  之间的距离要足够大。根据神经网络的特点，每层各神经元取值在 0

与 1 之间，而  $[0, 1]$  中一定存在某个值与  $f_{2j}(h, l)$  相差 0.5，这个与  $f_{2j}(h, l)$  相差 0.5 的值就是  $f_{22j}$ ，而且 0.5 的差距已经足够将变化类与未变化类区分开。

其次，ASDNN 根据所选取的样本的特征引入了自适应变化的学习率。在训练 ASDNN 的过程中，每次迭代之后，网络的参数就会有一次更新，即映射函数  $f_1$  就会得到更新，同时通过对比两幅图像所有像素对应的特征向量会得到该时刻的临时差异图，临时差异图将会影响 ASDNN 下一次的迭代。在得到临时差异图之后，首先将其归一化到 0 和 1 之间，然后利用 c 均值聚类 (FCM: fuzzy c-means)<sup>[47]</sup> 将临时差异图二分类。FCM 算法是一种软分割算法，已经广泛应用于图像分析中<sup>[48-51]</sup>。对于像素点  $(h, l)$ ，假设它在 FCM 分割之后相对于未变化类聚类中心与变化类聚类中心的分类隶属度分别为  $uu(h, l)$  和  $uc(h, l)$ 。 $uu(h, l) > 0.5$  并且像素点  $(h, l)$  被选作样本时，该样本参与训练时对应的学习率为  $uu(h, l) \times \theta$ ； $uc(h, l) \geq 0.5$  并且像素点  $(h, l)$  被选作样本时，该样本参与训练时对应的学习率为  $uc(h, l) \times \theta$ 。神经网络中学习率的取值一般在区间  $(0, 1)$  中选值，为了防止目标函数陷入局部最小值中无法跳出，学习率选取较小的值。在这里， $\theta$  的值被设定为 0.1。这样对每一个像素点设定不同学习率的目的是，在像素点  $(h, l)$  参与训练时将更新参数的步长设定为与该像素点属于未变化类或变化类的程度相关的系数。

最后，ASDNN 采取了全新的样本选择策略。INIR 方法在所有的像素点中随机选取样本参与到网络的训练中，SCCN 只选取了未变化类的像素点作为样本更新网络参数，这两种方法都会导致差异图对变化类区域和未变化类区域之间的差异性表达得不够明显，影响最后的变化检测的效果。观察式 (3-11)，可以发现目标函数中含有两个参数  $S_1(h, l)$  和  $S_2(h, l)$ ，这两个参数决定了像素点  $(h, l)$  是否会被选择为样本以及该样本对应何种类型的标签。为了获取  $S_1(h, l)$  和  $S_2(h, l)$  的值，需要引入两个公式，

$$\frac{N_{pq}[(p, q) \in \Omega_{h,l} \cap uu(p, q) \geq 0.5]}{N_{pq}[(p, q) \in \Omega_{h,l}]} \geq \beta \quad (3-13)$$

$$\frac{N_{pq}[(p, q) \in \Omega_{h,l} \cap uc(p, q) > 0.5]}{N_{pq}[(p, q) \in \Omega_{h,l}]} \geq \beta \quad (3-14)$$

$N_{pq}[r]$  是满足条件  $r$  的邻域窗口内像素点的数目， $\Omega_{h,l}$  是差异图中像素点  $(h, l)$  的邻域， $\beta \in (0.5, 1]$  是被手动定义的在区间内一个参数，它控制着所选取的样本的数目。在本文中， $\beta$  的值被设定为 0.7。当式 (3-13) 成立时， $S_1(h, l) = 1$ ，否则  $S_1(h, l) = 0$ ；当式 (3-14) 成立时， $S_2(h, l) = 1$ ，否则  $S_2(h, l) = 0$ 。前面标签的设定方式是以这种样本选择策略为基础的，不同类的样本对应着不同类的标签。选取两种类型的样本有利于生成未变化类区域与变化类区域差异性更加明显的差异图，以获取更加精确的变化检测结果。



ASDNN 在训练迭代的过程中, 只有图 3.3 中左半部分的网络参数进行更新, 而右半部分网络为左半部分网络的训练提供标签。具体的提供标签的方式在定义目标函数的时候已经做了详细的说明。ASDNN 在学习训练的过程中采用上述三项策略更符合异源图像变化检测任务, 利用 ASDNN 对异源图像进行变化检测的具体流程如下: 在差异信息学习的过程中,  $uu$  和  $uc$  对样本的选择起着决定性的作用, 引导

---

**算法 1** ASDNN 算法学习差异信息流程
 

---

**输入:** 两幅配准的异源遥感图像

**输出:** 变化检测结果图

- 1: 利用 ASDBM 初始化网络参数集  $\theta$  和特征向量
  - 2: 随机初始化  $uu$ : 所有元素的值都在  $[0, 1]$  内取值
  - 3: 根据 BP 算法更新  $\theta$
  - 4: 计算目标函数 (3-11) 的值
  - 5: 根据公式 (3-10) 计算差异图
  - 6: 利用 FCM 算法将差异图二分类, 更新  $uu$  和  $uc$  的值
  - 7: 循环: 从步骤 3 到步骤 6 循环直到目标函数 (3-11) 的值不再变化
  - 8: 根据公式 (3-10) 计算最终的差异图
  - 9: 利用 FCM 算法将差异图二分类, 得到变化检测结果图
- 

着深度神经网络的训练和参数的更新。一个像素点被选为未变化类和变化类所对应的标签是不一样的, 当像素点  $(h, l)$  属于未变化类且被选为了样本, 那么两幅图像在该像素点所对应的特征向量对之间的差异将被缩小, 相反, 当像素点  $(h, l)$  属于变化类且被选为了样本, 那么两幅图像在该像素点所对应的特征向量对之间的差异将被增大。所以, 在网络更新迭代的过程中, 差异图中的区域差异性越来越明显。另外值得注意的是, ASDNN 可以自发学习学习两幅图像的差异信息, 整个过程是完全无监督的, 不需要任何先验信息。

### 3.4 实验

ASDNN 能够生成未变化区域与变化区域差异性明显的差异图, 实验选取了三组图像集对 ASDNN 算法进行分析和验证。本章仍然选用了 S 形黄河数据集和曙光数据集对 ASDNN、SCCN 和 INIR 三种方法做对比实验分析, 另外还选择了一组同源数据集来验证基于深度神经网络的变化检测算法的可扩展性。该部分首先通过实验的方法确定了邻域窗口的尺寸  $n$  取得取值, 然后介绍了评价差异图的标准, 最后对三种方法做对比实验分析。

#### 3.4.1 邻域窗口的尺寸 $n$ 的选择

在 ASDNN 网络中,  $n$  的值是被手动设定的, 它也是唯一一个需要提前设定的参数。在学习差异信息的过程中, ASDNN 将固定窗口大小的邻域信息输入到网络

中，而且是在特征空间中分析两幅图像的差异性，所以邻域窗口的大小可能会影响到最后的变化检测结果。 $n$  的值越大，输入到网络中的邻域信息量越大，然而  $n$  的值并不是越大越好，当  $n > 5$  时，算法的计算复杂度明显提高，而且中心像素分类时受到邻域像素的影响太大，导致重心失衡，所以实际实验中并不考虑  $n > 5$  的情况。在 INIR 方法中，并没有对  $n$  的选取展开分析，原因是在基于重建的网络中，最终的目的还是在图像原本的维度空间分析差异性，提取的细节信息和抽象信息并没有直接用于分析差异性， $n$  的选取并不会造成重大影响，因此根据经验将  $n$  设定为 5。为了得到更加合理的  $n$  值，将  $n = 3, 5, 7, 9$  分别作用于两个选定的数据集上，实验结果如图 3.5 所示。




图 3.5 邻域窗口尺寸  $n$  对变化检测结果的影响

观察实验结果以及根据经验， $n = 5$  是最优取值。当  $n = 3$  时，所提取的邻域信息不够丰富，并不能获取足够高的变化检测精确度；当  $n > 5$  时，变化检测的精确度并不比  $n = 5$  的时候高，原因可能是过多的邻域信息会干扰 ADDNN 的判断。在之后的实验中， $n$  的取值都为 5。

### 3.4.2 差异图评价标准

差异图表示两幅被用于变化检测的遥感图像之间的差异程度，生成的差异图的质量决定着最终生成的变化检测结果的好坏。评价差异图的标准有受试者工作特征曲线 (ROC: Receiver Operating Characteristic Curve) 和查准率查全率曲线 (PR: Precision Recall)。ROC 曲线和 PR 曲线能够反映差异图中内在的特征。

ROC 曲线包含了两个变量，TPR 与 FPR。用所有可取的阈值对差异图分割，可以得到对应的所有的数据对 (FPR, TPR)。将 FPR 和 TPR 的值分别作为横坐标和纵坐标描绘在坐标系中，用光滑的曲线把所有的点连接就可以得到 ROC 曲线。ROC

曲线越靠近于左上角的 (0, 1) 点, 表示它所对应的差异图性能越好。此外, ROC 曲线和横坐标轴组成的有界限的区域的面积, 简称为 AUC, 可以定量评价差异图的性能, 计算出的 AUC 的值越大表示其对应的差异图性能越好。PC 曲线中也包含两个变量, P(Precision) 和 R(Recall), P 和 R 的计算方式为:

$$P = \frac{FP}{TP + FP} \quad (3-15)$$

$$R = \frac{TP}{TP + FN} \quad (3-16)$$

类似于 ROC 曲线, 用所有可能阈值分割差异图, 可以得到所有的 (P, R) 点集。在坐标系中将所有的这些点用平滑的曲线连接就是 PR 曲线, PR 曲线与横坐标轴组成的区域的面积就是 AUP 值。PR 曲线越接近于 (1, 1) 以及 AUP 的值越大, 表明其所对应的差异图性能越好, 反之亦然。

差异图的性能是评估变化检测算法有效性的重要指标。在实验中, ROC 曲线和 PR 曲线是用来定性分析差异图的好坏, 它们所对应的面积 AUC 和 AUP 是定量的精确度。将这四标准之前的分来标准结合, 能够更加综合地评价变化检测算法。

### 3.4.3 异源遥感图像的实验结果与分析

实验分析部分从差异图的性能和变化检测的精度两方面综合评价变化检测算法, 在异源遥感图像的效果验证仍然选取了 S 形黄河数据集和曙光数据集。ASDNN 与 INIR 和 SCCN 的不同之处在于定义了一个新的目标函数, 采用了自适应变化的学习率, 并引入了一个全新的样本选择策略。INIR 将全随机选取像素点作为样本, SCCN 选取未变化类的像素点作为样本, 它们对于两类区域的解析都不够全面。这三种基于深度神经网络的算法在对异源图像进行变化检测的过程中都有差异图的生成, 差异图的性能对最后变化检测的结果有着决定性的作用, 所以对差异图的分析是实验分析部分的重点之一。

表 3.1 ASDNN、SCCN、INIR 在 S 形黄河数据集上的变化检测精度对比

评价指标 算法	AUR	AUP	OE	CA	KC
ASDNN	0.9156	0.7085	0.0252	0.9748	0.6218
SCCN	0.8175	0.6684	0.0354	0.9646	0.5787
INIR	0.6043	0.5566	0.0309	0.9691	0.5074

将 ASDNN、SCCN、INIR 算法应用于 S 形黄河数据集上, 实验结果如图 3.6 所示。图 3.6(a)-3.6(c) 是各算法生成的差异图, 图 3.6(d)-3.6(f) 是对应的二分类后的结果图, 即变化检测的结果图。在差异图和结果图中, ASDNN 的结果中噪声是最少




图 3.6 ASDNN、SCCN、INIR 在 S 形黄河数据集上生成的差异图 and 变化检测结果图




图 3.7 ASDNN、SCCN、INIR 在 S 形黄河数据集上生成的差异图对应的 ROC 曲线和 PR 曲线

的。与之前的评价标准不同的是，在这三种算法的对比试验中，我们添加了对差异图性能的评价标准 ROC 曲线和 PR 曲线以及两种指标对应的 AUC 值和 AUP 值。当 ROC 曲线越靠近左上角 (0,1) 点且 AUC 对应的值越大，或者 PR 曲线越靠近 (1,1) 点且 AUP 的值越大，表示差异图的性能越好。三种算法的 ROC 曲线和 PR 曲线如图 3.7 所示。观察图 3.7，ASDNN 的对应的 ROC 曲线最接近于点 (0,1)，SCCN 次之，INIR 对应的 ROC 曲线距点 (0,1) 最远；ASDNN 对应的 PR 曲线最接近于点 (1,1)，INIR 对应的 PR 曲线距点 (1,1) 最远。从评价标准量化的角度分析，表 3.1 以及图 3.8 清晰展示了三种方法在各个评价指标上的数值对比结果，ASDNN 的变化检测精




图 3.8 ASDNN、SCCN、INIR算法在 S 形黄河数据集上检测精度表现

精度 KC 和差异图的性能 AUC 及 AUP 的取值都是最高的。另外，ASDNN 算法的检测错误率 OE 的取值也是最低的。因此，在样本选择和标签设定方面改进的 ASDNN 算法是三种算法在异源遥感图像变化检测应用中效果最好的。所以，样本的选择对基于深度神经网络的变化检测至关重要，同时还要为样本设定合适的标签值。在第二章中的实验结果表明，基于邻域信息重建的 INIR 算法的效果要明显好于传统的 PCC 算法，而且 PCC 算法并没有生成差异图，所以在本章的实验中，我们不再将基于深度神经网络的变化检测算法与传统的 PCC 做对比。

表 3.2 ASDNN、SCCN、INIR 在曙光数据集上的变化检测精度对比

评价指标 算法	AUR	AUP	OE	CA	KC
ASDNN	0.9909	0.8823	0.0207	0.9793	0.7655
SCCN	0.9643	0.7239	0.0477	0.9523	0.5563
INIR	0.9393	0.6556	0.0616	0.9384	0.5049

将 ASDNN、SCCN、INIR 算法应用于曙光数据集上，实验结果如图 3.9 所示。图 3.9(a)-3.9(c) 是各算法生成的差异图，图 3.9(d)-3.9(f) 是对应的差异图二分类后的结果图，即变化检测的结果图。在差异图和结果图中，ASDNN 的结果中噪声是最少的。观察图 3.7，ASDNN 对应的 ROC 曲线最接近于点 (0, 1)，SCCN 次之，INIR 对应的 ROC 曲线距离点 (0, 1) 最远；ASDNN 对应的 PR 曲线最接近于点 (1, 1)，SCCN 次之，INIR 对应的 PR 曲线距离点 (1, 1) 最远。从评价标准量化的角度分析，表 3.2 和图 3.11 清晰展示了三种方法在各个评价指标上的数值对比结果，ASDNN 的变化检测精确度 KC 值和差异图的性能 AUC 及 AUP 的取值都是最高的。尤其在图 3.11 中，可以更加明了地对比 ASDNN 与其他两个算法在各个评价指标上的取值，它在

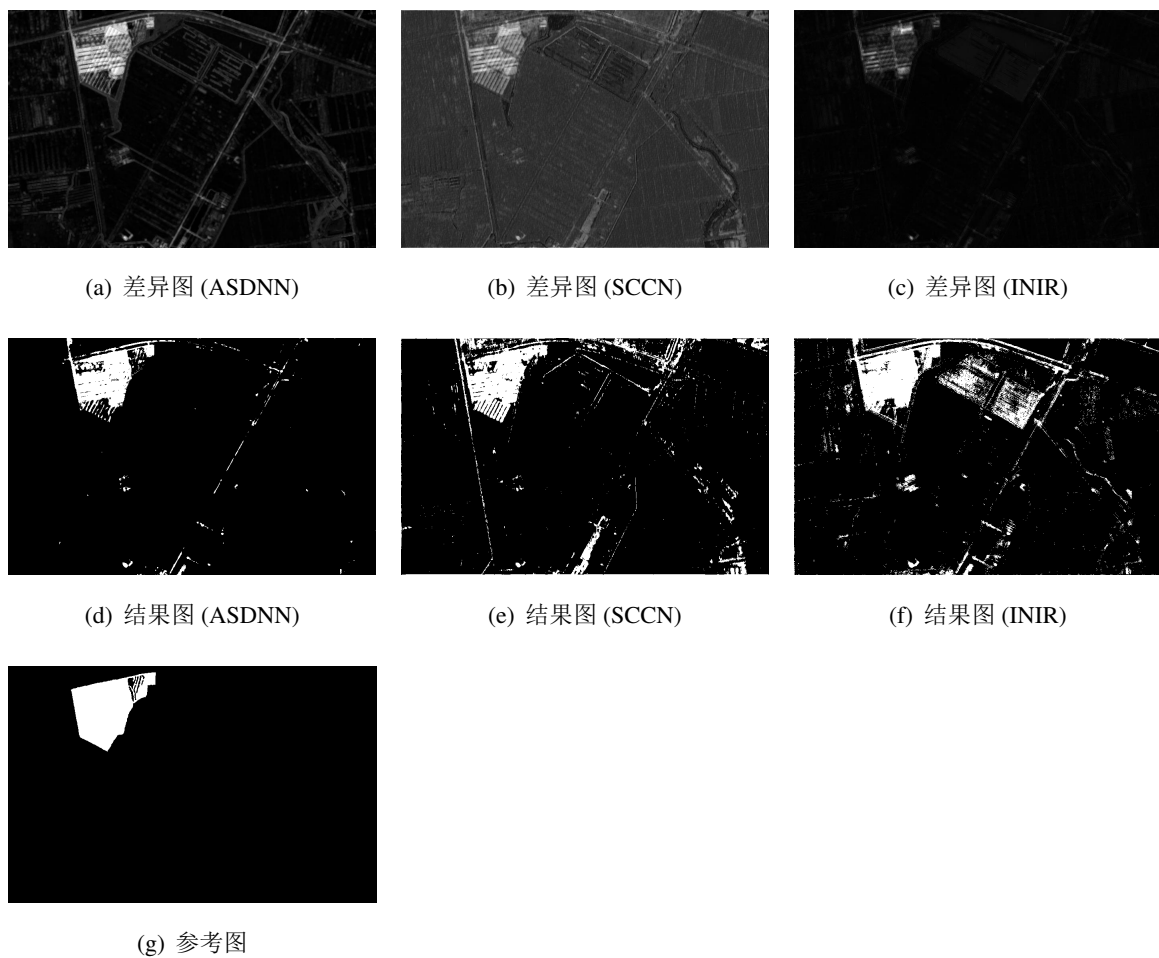


图 3.9 ASDNN、SCCN、INIR 在 S 形黄河数据集上的差异图 and 变化检测结果图




图 3.10 ASDNN、SCCN、INIR 在曙光数据集上的 ROC 曲线和 PR 曲线

每个检测性能指标中的表现都是最好的。在曙光数据集上，ASDNN 的优势更加明显，因为在这个数据集中，每幅遥感图像含有的景象类别相比于 S 形黄河数据集更多。在黄河数据集中每幅遥感图像中只含有两个类别，河流和陆地。而曙光数据集中含有河流、陆地、庄稼等多个类别的景象，因此更加需要全面的样本对深度神经




图 3.11 ASDNN、SCCN、INIR 算法在曙光数据集数据集上检测精度表现

网络进行训练。ASDNN 在选取样本时考虑了未变化区域和变化区域两种情况，并对两种情况下的标签的取值做了区别处理，这些措施使得它在差异信息表示和结果精确度上有更加出色的表现。对比 ASDNN、SCCN 和 INIR 算法的实验结果表明，ASDNN 算法是三种算法在异源遥感图像变化检测应用中效果最好的。

综合两个数据集的相关实验结果，ASDNN 算法无论是在结果图精确度上，还是生成的差异图性能上，表现都是最好的，它可以很好地应用到异源遥感图像的变化检测中。与 SCCN 和 INIR 算法相比，ASDNN 算法能取得最优的结果，主要原因是 ASDNN 从未变化类与变化类两类中选取样本，并根据数据的特征设定了对应的两种类别的标签。另外，ASDNN 还根据样本在 FCM 分类时的隶属度，采用了自适应变化的学习率。基于上述改进，ASDNN 在网络更新迭代的过程中，可以学习到输入到网络中的两幅异源遥感图像之间的差异信息，生成对差异信息表示得更加丰富的差异图，从而得到精确度较高的变化检测结果。SCCN 和 INIR 也都是基于深度神经网络的变化检测算法，但是它们对于样本的选取存在不足之处。INIR 算法将随机选取的像素点作为样本来训练网络，这会导致重建的邻域信息在所有区域都很接近于被重建的邻域信息，所以生成的参考图中变化区域与未变化区域的差异很小，获得的变化检测结果的精确度不理想。SCCN 算法意识到了不能将所有像素点作为样本，但是它只选取了未变化区域的像素点作为样本，没有学习变化区域的信息，所以它生成的结果只是相对于 INIR 算法有所提高，并没有达到理想的精确度。综上所述，本文所提出的 ASDNN 算法能够生成很好地表示差异信息的差异图，获取具有较高精度的变化检测结果。

### 3.4.4 同源遥感图像的实验结果与分析

基于深度神经网络的图像变化检测算法的本质是从图像中提取细节和抽象信息，



利用所提取的信息分析两幅遥感图像之间的差异，所以对同源遥感图像也是同样适用的。在同源图像的实验结果分析中，我们只选用了 ASDNN 和 SCCN 两种算法与传统的算法对比，摒弃了 INIR 算法。因为 INIR 算法中随机选取样本参与训练，而且对于两种类别没有区别分析和应对的策略。在同源图像中，两幅配准的图像对于同种景象在像素值上有着近似的表达，随机选取样本参与网络的训练导致生成的差异图并不能表达变化区域与非变化区域的差异。传统生成差异图的算法选用的是 MR 算法和 LR 算法。

实验选取的同源遥感图像的数据集是 Ottawa 数据集，如图 3.12 所示。数据集中三幅图像的大小是  $301 \times 301$ ，分辨率相同。图 3.12(a) 是一幅 SAR 图像，图 3.12(b) 也是是一幅 SAR 图像，两幅图像是分别于 1997 年 5 月和 8 月拍摄的渥太华的景象。图 3.12(c) 是变化检测结果的参考图，它是根据图 3.12(a) 和图 3.12(b) 的像素特征以及先验信息手动描绘的。




图 3.12 Ottawa数据集

MR 算法采用的是一种平均策略，可以消除邻域中离异值的影响<sup>[52]</sup>；LR 算法采用的是比值策略，将乘性噪声转化为加性噪声<sup>[53]</sup>；SCCN 和 ASDNN 都是基于神经网络的方法，利用从图像中提取的细节和抽象信息分析差异性。SCCN 主要考虑了未变化区域像素点作为样本，ASDNN 考虑了未变化区域和变化区域两类样本。ASDNN 和 SCCN 的设计初衷是为了解决异源遥感图像变化检测问题，但是也可以应用与同源图像的变化检测。四种算法在 Ottawa 数据集上的变化检测结果如图 3.13 所示，图 3.13(a)-3.13(d) 是四种方法生成的差异图，图 3.13(e)-3.13(h) 是四幅差异图对应的二分类后的变化检测结果图。MR 方法生成的差异图以及变化检测的结果图中还有很多的噪声，LR 的结果图 3.13(b) 和 3.13(f) 中虽然还有些离异值噪声，但是相比 MR 的结果噪声明显减少。基于神经网络的方法可以很好的处理这些噪声。SCCN 和 ASDNN 获得结果中的噪声要明显少于传统的方法。但是由于 SCCN 的训练样本只从未变化类中选取，所以差异图对这两种类别区域的差异性在像素值上表现的不够明显。而 ASDNN 选取了两类样本参与到网络的迭代更新中，所以差异图实现了对变化的区域突出表示。图 3.14 ROC 曲线和 PC 曲线对差异图的分析中，



ASDNN 的差异图性能是最好的，它的 ROC 曲线最接近于点 (0, 1)，PR 曲线最接近于点 (1, 1)，并且 ROC 曲线与 PR 曲线对应的 AUC 和 AUP 的值也是相对最高的。表 3.3 和图 3.15 展示了四种方法在各个评价指标上的对比，综合评价指标 KC 的值和分类精度 CA 的值中，ASDNN 的取值是最高的，并且它的分类错误率 OE 的值也是最低的。很明显，ASDNN 在差异图和最后的变化检测结果中的表现都是最好的。




图 3.13 MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上生成的差异图和变化检测结果




图 3.14 MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上的 ROC 曲线和 PR 曲线

同源遥感图像数据集上的实验结果表明，基于神经网络的方法要好于传统的方法。得益于优秀的学习机制，ASDNN 算法在各个方面的表现都是最好的。但是，和异源遥感图像的实验结果相比，基于深度神经网络的算法的优势不是那么明显。原因是对于这种单通道的同源遥感图像而言，它们在低维空间可以直接进行像素值的比较，而且相对来说传统的方法操作更加简单和易于理解。LR 算法在没有

表 3.3 MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上变化检测的精确度对比

评价指标 算法	AUR	AUP	OE	CA	KC
MR	0.9238	0.8987	0.1426	0.8574	0.5908
LR	0.9207	0.8987	0.0538	0.9520	0.8171
SCCN	0.9688	0.9312	0.0475	0.9576	0.8369
ASDNN	0.9798	0.9425	0.0392	0.9608	0.8458

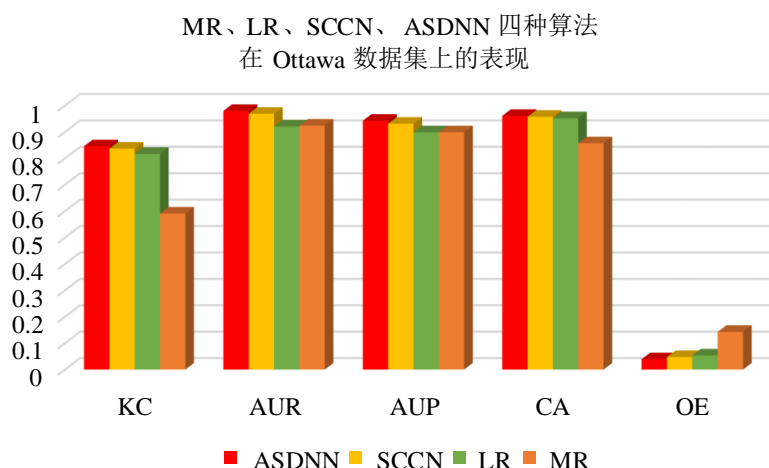


图 3.15 MR、LR、SCCN、ASDNN 四种算法在 Ottawa 数据集上检测精度表现

添加任何后处理的情况下，变化检测的精确度 KC 的值已经很逼近 ASDNN 的结果。另外，基于神经网络的变化检测算法需要经过网络的参数迭代更新过程，这些算法的时间复杂度肯定要比类似 LR 的传统算法要高，微弱的精度的提高却要投入多花费几十倍时间的代价，目前看来并不太可取。所以，对于单通道的同源遥感图像，更倾向于采取传统的方法来实现变化检测。

### 3.4.5 ASDNN 算法的时间复杂度

算法的时间复杂度是指解决问题的算法的运行时间。ASDNN 算法不仅对遥感图像变化检测的精度高，而且其在时间复杂度上也具有明显的优势。ASDNN 变化检测的精度高已经由上述的实验被证明，其在时间复杂度上的表现也将通过实验加以证明。

ASDNN 算法首先由 ASDBM 初始化，然后在循环选取样本和更新参数中学习两幅图像的差异信息，最后输出变化检测的结果。与之前基于神经网络的变化检测算法最大的不同是 ASDNN 在训练过程中选取两类样本并设定了两类标签，但是 ASDNN 算法的复杂度并不高。因为它通过式 (3-13) 和式 (3-14) 选取了部分像素点

作为样本参与到网络的训练，不仅提高了变化检测的精度，还降低了整个算法的时间复杂度。ASDNN 算法的整个学习过程如 **算法1** 所示。每次的迭代都从样本选取开始，以 FCM 分割差异图结束。假设一幅图像中所含有的像素点的个数为  $N$ ，选取的样本占有所有像素点的比例为  $\alpha$ ，那么 ASDNN 迭代过程的时间复杂度为  $O(\alpha N)$ 。 $\alpha$  是由每次迭代时 FCM 分割差异图的结果来确定的，并不是一个常量，因此不能被忽略。

SCCN 算法也主要包含三个步骤，初始化、网络学习和结果输出。在网络学习的过程中，SCCN 算法的样本是通过阈值的方法选取的未变化区域的像素点。假设样本占有所有像素点的比例为  $\alpha_0$ ，那么 SCCN 算法的复杂度为  $O(\alpha_0 N)$ 。同样， $\alpha_0$  不是一个常量，也不能被忽略。




图 3.16 裁剪的各个子集的参考图

为了比较 ASDNN 算法和 SCCN 算法的时间复杂度，我们将曙光数据集裁剪成不同的尺寸，统计两种算法在每个子数据集上完成变化检测所需要的时间以及相对应的变化检测精度 KC 的值。被裁剪出的各个子集的参考图如图 3.16 所示，每个子集都包含原数据集中完整的变化区域。ASDNN 和 SCCN 作用于各个子集所获得的变化检测的结果如图 3.17 所示，图 3.17(a)-3.17(d) 是 ASDNN 的结果，图 3.17(e)-3.17(h) 是 SCCN 的结果。观察两种方法获得结果图，可以看出 SCCN 的结果图相比 ASDNN 遗漏了很多属于变化区域的像素点，这是 SCCN 在抽取样本方面的不足导致的。

ASDNN 在时间复杂度和变化检测精度 KC 值中都占有明显的优势，图 3.18 直观展示了这个结果。ASDNN 是从变化类与未变化类两个类别中选取样本，而 SCCN 只在未变化类中选取样本，但是在算法实际实施的过程中， $\alpha$  的值要比  $\alpha$  的值小，原因是 ASDNN 在选取样本时，只选取满足式 (3-13) 和式 (3-14) 的样本。ASDNN 的样本选择策略和标签设定规则在另一方面也保证了算法的变化检测精度。




图 3.17 ASDNN 和 SCCN 在各子集上的变化检测结果




图 3.18 ASDNN 和 SCCN 在曙光数据集及其子集上变化检测的时间和 KC 值

### 3.5 本章总结

本章提出了一种基于差异信息学习的异源图像变化检测算法，即 ASDNN 算法。该算法利用一种类对称的深度神经网络，将两幅异源遥感图像映射到同一特征空间，在特征空间分析两幅图像的差异信息，从而学习到对应的差异图。ASDNN 算法与以往基于深度神经网络的图像变化检测算法的不同之处在于，它设定规则从未变化类与变化类中分别选取了样本，并根据当前参与训练样本的自身特征设定了对应的两种类别的标签，采取自适应变化的学习率。这些策略保证了 ASDNN 学习差异信息的全面性。

本章首先介绍了一种概率生成式模型 RBM，RBM 的两层网络结构是输入信息的两种不同的表达方式。RBM 主要用于初始化神经网络，消除随机初始化对训练迭代的影响，本文利用堆叠的 RBM 初始化深度神经网络。其次介绍了最新被提出的一种用于异源图像变化检测的 SCCN 算法，SCCN 利用阈值法从未变化类中提取样本更新网络参数，这种样本选取方式使得它对差异信息的表达不够全面。然后详细阐述了本章中提出的 ASDNN 算法，包括 ASDNN 的网络结构、样本选取、学习机制等。最后从实验的角度对比分析了 INIR、SCCN 和 ASDNN 三种算法，证明了 ASDNN 的相对优势以及用于异源遥感图像变化检测的有效性，另外还验证了 ASDNN 算法具有较低时间复杂度。

本章提出的 ASDNN 算法是完全无监督的，不需要任何的先验信息，它根据两类的样本能够很好地学习到两幅异源遥感图像之间的差异信息，获取具有较高精度的变化检测结果。在算法的学习流程中，提出了从未变化类和变化类两种区域中挑选样本，这种策略对于之后基于深度神经网络的异源图像变化检测研究具有很大的启发意义。



## 第四章 基于伪标签学习的异源图像变化检测

基于伪标签学习的异源图像变化检测方法 (SLL: Simulated Labels Learning) 仍然利用的是类对称的深度神经网络将两幅异源遥感图像转化到同一特征空间, 在特征空间分析两幅图像之间的差异。SLL 重新制定了变化类样本的伪标签取值方式, 进一步提升了差异图中的未变化类与变化类之间的差异程度, 同时也使得网络更加稳定。另外, SLL 使用改进的模糊聚类算法对生成的差异图二分类, 进一步提高了变化检测的精度。本章首先介绍了改进的模糊聚类算法, 然后对 SLL 方法做了详细的描述, 接着进行了实验验证。

### 4.1 基于空间信息的模糊聚类算法

模糊 C 均值聚类 (FCM) 使用了元素隶属度的思想, 隶属度描述待分类元素属于某一类的程度。FCM 算法相对于硬聚类算法保留了更多的信息, 具有很好的稳健性, 所以这种算法被广泛地运用于图像分割中。但是原始的 FCM 算法并不将被分割像素点的上下空间信息纳入考虑范围, 对噪声和其他成像伪影比较敏感, 在实际领域的应用中受到非常多的限制。为了弥补传统 FCM 聚类分割的缺点, 相关研究人员设法将局部相关空间信息纳入进原始的 FCM 算法, 以期在分割的过程中去噪, 提高图像分割的性能。其中效果较显著的有 Ahmed 和 Yamany 等人提出的 FCM-S<sup>[54]</sup>, Szilagyi 和 Benyo 等人提出的增强型 FCM 算法 EnFCM<sup>[48]</sup>, 以及 Cai 和 Chen 等人提出的广义快速 FCM 算法 FGFCM<sup>[50]</sup>, 但是这些方法都有需要手动选择一定量的参数, 缺乏鲁棒性。随后 S.Krinidis 和 V.Chatzis 在 2010 年提出了 FLICM<sup>[47]</sup>算法, 它也是一种考虑空间信息影响的新颖聚类算法, FLICM 算法不需要手动选择相关的约束参数。

FLICM 在 FCM-S 等算法的基础上重新定义了与空间信息相关的约束项参数, 它是一种考虑了局部相关信息的 c 均值聚类算法。FLICM 算法的目标函数如下:

$$J = \sum_i^N \sum_j^c (u_{ji}^m \|p_i - c_j\|^2 + G_{ji}) \quad (4-1)$$

$$G_{ji} = \sum_{r \in N_i, r \neq i} l_{sr} (1 - u_{jr}^m) \|p_r - c_j\|^2 \quad (4-2)$$

$$l_{sr} = \frac{1}{1 + d_{ir}} \quad (4-3)$$

隶属度矩阵和聚类中心的更新如下：

$$u_{ji} = \frac{1}{\sum_{k=1}^c \left( \frac{\|p_i - c_j\|^2 + G_{ji}}{\|p_i - c_k\|^2 + G_{ki}} \right)^{1/(m-1)}} \quad (4-4)$$

$$c_j = \frac{\sum_{i=1}^N u_{ji}^m p_i}{\sum_{i=1}^N u_{ji}^m} \quad (4-5)$$

$p_i$  是图像中像素  $i$  的灰度值， $N$  是总的像素数目； $2 \leq c \leq N$ ，是聚类的数目； $u_{ji}$  是在数据集中  $p_i$  属于第  $j$  类的隶属度， $0 \leq u_{ji} \leq 1$ ，且某个像素对各聚类的隶属度之和为 1； $m \in [1, +\infty)$  是每个模糊隶属度的权重指数； $c_j$  是第  $j$  类的聚类中心。 $p_r$  表示以  $p_i$  为中心像素的邻域窗口内的领域像素， $N_i$  表示以像素  $i$  为中心的邻域窗口内像素的集合； $l_{sr}$  表示邻域像素  $p_r$  对中心像素的抑制系数。

FLICM 算法重新定义了目标函数中的惩罚项，这个新的惩罚项的相对优点：将局部空间和灰度信息以模糊的方式整合，对噪声具有鲁棒性；使用原始图像，避免可能引起图像细节信息丢失的预处理步骤；另外，FLICM 算法不受任何参数选择的限制。

## 4.2 基于伪标签学习的方法描述

基于伪标签学习的异源图像变化检测方法仍然利用的是类对称的深度学习神经网络将两幅异源遥感图像转化到同一特征空间，在特征空间分析两幅图像之间的差异。SLL 重新设计变化类样本中标签的取值方式以获取更加丰富的差异信息，并利用改进的模糊聚类算法对生成的差异图二分类。

### 4.2.1 伪标签的设定

基于深度神经网络的无监督自动选取样本的异源图像变化检测方法有 SCCN 和论文提出的 ASDNN。SCCN 在选取样本时考虑到变化类不能与未变化类使用相同类型的标签，但是它选择放弃变化类样本的训练。ASDNN 提出变化类的信息也应该被模型学习，将变化类的样本输入到网络中参与训练，它为变化类与未变化类设定了不同类别的标签值，在缩小未变化类区域像素对应的特征向量对之间的距离的同时，增大了变化类区域像素对应的特征向量对之间的差异。ASDNN 的学习机制使得生成的差异图能够更加全面地反映两幅异源遥感图像之间像素级的差异程度。但是，ASDNN 中的标签值设定规则仍然有一定的不足之处。在 ASDNN 中，当像素点



$(h, l)$  被选为变化类的样本时，它在训练时对应的标签是  $f_{22}$ ， $f_{22}$  的设定规则为：

$$f_{22j}(h, l) = \begin{cases} f_{2j}(h, l) - 0.5 & f_2(h, l) \geq 0.5 \\ f_{2j}(h, l) + 0.5 & else \end{cases} \quad (4-6)$$

$f_{2j}(h, l)$  是特征向量  $f_2(h, l)$  中第  $j$  个节点的值。ASDNN 选择将  $f_{2j}(h, l)$  与  $f_{22j}(h, l)$  的距离设定为 0.5 的原因是两者的取值必须保证在  $[0, 1]$  区间内，而且 0.5 的间距已经足够将变化类与未变化类区分开。但是这样的设定方式仍然有一些不足之处。如果特征向量  $f_1(h, l)$  中第  $j$  个节点的值为  $f_{1j}(h, l) = 0.1$ ，相应的  $f_{2j}(h, l) = 0.9$ ，此时  $f_{1j}(h, l)$  与  $f_{2j}(h, l)$  的差值为 0.8，但是在训练时为  $f_{1j}(h, l)$  设定的标签值  $f_{22j}(h, l) = 0.9 - 0.5 = 0.4$ ，那么在训练稳定后， $f_{1j}(h, l)$  与  $f_{2j}(h, l)$  的差值应该为  $0.9 - 0.4 = 0.5$ 。这样的话， $f_{1j}(h, l)$  与  $f_{2j}(h, l)$  的差值在训练稳定后反而比训练稳定前还小。这样的情况在  $f_{2j} > 0.5$  且  $f_{2j}(h, l) - 0.5 > f_{1j}(h, l)$  时以及  $f_{2j}(h, l) < 0.5$  且  $f_{2j}(h, l) + 0.5 < f_{1j}(h, l)$  时都会存在。虽然 0.5 的差距已经足够，但是变化区域像各素点的特征向量对之间的差距越大越好，才能更有利于将变化区域与未变化区域区分开。

基于 ASDNN 上述不足之处，论文对变化类样本的标签值重新做了调整。当像素点  $(h, l)$  被选为变化类的样本时，它在训练时对应的标签是  $f_{22}$ ， $f_{22}$  的设定规则为：

$$f_{22j}(h, l) = \begin{cases} 0 & f_2(h, l) \geq 0.5 \\ 1 & else \end{cases} \quad (4-7)$$

$f_{2j}(h, l)$  是特征向量  $f_2(h, l)$  中第  $j$  个节点的值。在任何情况下， $f_{22j}(h, l)$  的取值都是在  $[0, 1]$  区间内与  $f_{2j}(h, l)$  相距最远的点，可以最大化向量  $f_1(h, l)$  与  $f_2(h, l)$  之间的差异。将符合条件的样本输入到网络中进行训练，参数更新完成后所生成的差异图可以为生成精度更高的变化结果图奠定基础。

#### 4.2.2 SLL 学习过程

SLL 使用了与 ASDNN 相同的网络结构，将两幅用于变化检测的遥感图像映射到同一特征空间，在特征空间中对两幅图像之间的差异，从而生成差异图。RBM 是一种生成式概率模型，其结构中的隐含层和可视层是输入信息的两种不同的表达方式，网络使用多层受限玻尔兹曼机 RBMs 结构初始化，减少了随机因素对变化检测的影响，使得得到的结果更加稳定。

SLL 在选取样本时，重新设定了对变化类样本的标签的取值方式，并且采用改进的模糊聚类算法 FLICM 对生成的差异图二分类。SLL 对异源遥感图像进行变化检




图 4.1 SLL 变化检测流程图

测的流程如图 4.1 所示。引导整个学习过程的目标函数仍然是：

$$\begin{aligned}
 Q(\theta) &= \sum_{h,l} F(h,l) \\
 &= \frac{1}{2} \frac{1}{\sum_{h,l} (S_1) + \sum_{h,l} (S_2)} \sum_{h,l} (S_1(h,l) \|f_1(h,l) - f_2(h,l)\|_2 \\
 &\quad + S_2(h,l) \|f_1(h,l) - f_{22}(h,l)\|_2) \\
 &\quad s.t. (1 \leq h \leq H, 1 \leq l \leq L)
 \end{aligned} \tag{4-8}$$

其中  $\theta = \{W, b\}$  代表网络参数， $Net_1$  与  $Net_2$  分别表示图 3.3 中的左半网络和右半网络，函数  $f_{22}$  的引入是为了扩大  $f_1(h, l)$  和  $f_2(h, l)$  之间的距离，它的定义方式为式 (4-6)，这是与 ASDNN 最大的不同之处。对  $f_{22}$  做修正的目的是最大化向量  $f_1(h, l)$

与  $f_2(h, l)$  之间的差异。另外, 获取更高精度的变化检测结果, SLL 使用了基于空间信息的模糊聚类 FLICM 算法分割差异图。由于 FLICM 算法的复杂度相对 FCM 算法要高很多, 为了提高整个变化检测的时间效率, 在网络训练过程中依然使用 FCM 算法更新  $uu$  和  $uc$ 。SLL 完善样本标签值的设定方式以及利用模糊聚类算法 FLICM 的初衷是为了生成能更好表示差异信息的差异图, 以获取精确度更好的变化检测结果。

### 4.3 实验

用于异源遥感图像变化检测的 SLL 算法是在 ASDNN 的基础上改进的, 改进的目的是生成精确度更高的变化检测结果图。在第三章中, ASDNN 与 SCCN 和 INIR 算法在各方面做了详细地对比分析, 结果表明 ASDNN 算法在异源遥感图像变化检测问题上的表现是最好的。所以, 在对 SLL 进行实验分析时, 只将 ASDNN 作为对比算法。

实验选取曙光数据集的各个子集来分析 SLL 算法对异源遥感图像变化检测的有效性。各子集的参考图如图 3.16 所示, 所选择的每个子集都包含原数据集中完整的变化区域。在实际应用中, 变化区域占据全图的比例是不可控的, 将裁剪的各个子集作为实验验证的数据集可以分析这个因素是否会影响到最终变化检测的结果。为了说明改进伪标签的取值设定方式对变化检测的效果, SLL 生成差异图后, 也会采用 FCM 算法分割差异图, 将 FCM 二分类后的结果与 ASDNN 的结果对比。ASDNN 算法在子集 A、B、C、D 上的实验结果图如图 4.2 所示。SLL 算法在子集 A、B、C、D 上的实验结果图如图 4.3 所示, 其中图 4.3(a)-4.3(d) 是利用 FCM 算法对生成的差异图二分类的结果, 图 4.3(e)-4.3(h) 是 FLICM 算法对生成的差异图二分类的结果。




图 4.2 ASDNN 在曙光数据集各子集上的变化检测结果




图 4.3 SLL 在曙光数据集各子集上的变化检测结果

表 4.1 ASDNN 和 SLL 在曙光数据集子集上变化检测的精确度对比

评价指标 数据集	KC(ASDNN)	KC(SLL_FCM)	KC(SLL_FLICM)
子集 A	0.7792	0.8064	0.8601
子集 B	0.7258	0.7727	0.7954
子集 C	0.7638	0.7935	0.8127
子集 D	0.7261	0.7738	0.7848

把 ASDNN 的获取的实验结果与 SLL 中利用 FCM 二分类的结果对比, 仔细对比不难看出图 4.3(a)-4.3(d) 的结果中细节更加清晰明确。而对比 SLL 中 FCM 的二分类结果和 FLICM 的二分类结果, 图 4.3(e)-4.3(h) 的结果更加平滑, 去除了一些离异噪声。表 4.1 中将三种结果的精度值 KC 对比。首先, SLL 中 FCM 的二分类结果的 KC 值相比于 ASDNN 的结果有所提升, 说明对变化类伪标签的取值方式重新设定是

有效的。另外，SLL 中 FLICM 的二分类结果相比于 FCM 的结果又有了进一步的提升，所以选取一个好的分类算法也在一定程度上改进了算法的性能。因此，总体上 SLL 在异源遥感图像的变化检测上取得了很大的进步。

实验结果表明，SLL 算法在异源遥感图像变化检测上是优于 ASDNN 算法的。这就说明，SLL 算法采取新的伪标签值的设定方式以及选用结合空间邻域信息的聚类算法分割差异图是有效的。

## 4.4 本章总结

本章提出了一种基于伪标签学习的异源遥感图像变化检测算法，该算法是基于 ASDNN 的改进算法。SLL 优化了训练网络时的伪标签设定方式，最大程度地增大变化区域对应的特征向量对之间的距离，以提升最后变化检测结果的精度。此外，SLL 选用 FLICM 算法对生成的差异图二分类，FLICM 是一种结合空间信息的聚类分割算法，在一定程度上减弱了噪声对结果的影响。在曙光数据集各子集的实验结果表明，SLL 在异源遥感图像上变化检测的精度要优于 ASDNN 算法。

本章首先介绍了结合空间信息的 FLICM 算法，该算法是一种分割精度更好的无监督聚类算法。然后详细描述了 SLL 算法的细节，尤其是重新设定的标签值的取值方式。最后在曙光数据集各子集上验证了 SLL 算法的有效性。SLL 算法不论是最后变化检测的精度上，还是网络优化过程稳定性上，都要优于 ASDNN 算法。

是在  
还是在？



## 第五章 总结与展望

### 5.1 总结

异源遥感图像对同一种地表特征有着不同的像素灰度值表示，因此异源遥感图像的变化检测非常具有挑战性，不能直接在原始低维空间直接做差异分析。本文将深度神经网络应用于异源图像的变化检测，利用从图像中提取的特征信息分析两幅图像之间的差异信息，总共做了三个相关工作。这三项工作逐步提高了遥感领域中异源图像变化检测结果的精度。第二章提出基于图像邻域信息重建的异源图像变化检测，利用深度神经网络重建图像邻域信息，根据重建误差生成对应的差异图；第三章提出基于差异信息学习的异源图像变化检测，将两幅异源图像映射到特征空间，在特征空间分析两幅图像的差异信息，根据既定的规则从未变化类与变化类均提取样本，使差异图能更好地表示未变化区域与变化区域之间的差异；第四章提出基于伪标签学习的异源遥感图像变化检测，重新设定了变化类样本对应标签的取值规则，最大程度地增大变化类与未变化类的区别，并采用了改进的聚类算法分割差异图，提高变化检测结果的精度。在异源遥感图像数据集上的实验结果表明了这三种基于深度神经网络的方法在异源遥感图像变化检测问题中的有效性。

基于深度神经网络的变化检测算法巧妙避开了在原始数据空间对比两幅图像的信息，通过提取图像中的细节特征和抽象特征来分析图像差异性，生成差异图。另外，上述三种基于深度神经网络的异源遥感图像变化检测算法是完全非监督的且不需要手动提取样本的，而且后两种方法中样本的选择是在网络迭代更新过程中根据特征信息自动选取的，提高了差异图在差异信息表现方面的性能，获取了高精度的变化检测结果。

基于深度神经网络的异源图像变化检测方法表现出了良好的性能，然而由于网络参数需要迭代更新，无法避免的是这类算法相比于传统算法时间复杂度更高。基于差异信息学习和伪标签学习的方法在这方面做了改进，时间复杂度有所降低。另外，基于深度神经网络的变化检测算法还能够引用到同源遥感图像中，但是由于同源遥感图像可以直接在原始数据空间做差异分析，从时间复杂度方面考虑，不建议使用深度神经网络分析同源遥感图像。

### 5.2 展望

本文中为了分析两幅异源遥感图像的差异信息，利用两个网络将图像映射到特征空间。为了更全面分析两幅图像中的特征信息，之后的研究中在克服自动化提取

样本这个难题后，可以考虑将两幅图像同时输入到同一个网络中提取相结合的信息。另外，可以标记大量的遥感图像样本，将自然图像中的目标识别模型应用到遥感图像中，实现各类地表景象的自动识别。



## 参考文献

- [1] PLOWRIGHT A A, COOPS N C, CHANCE C M, et al. Multi-scale analysis of relationship between imperviousness and urban tree height using airborne remote sensing[J]. Remote Sensing of Environment, 2017, 194 : 391–400.
- [2] POSSELT R, MUELLER R W, ST?CKLI R, et al. Remote sensing of solar surface radiation for climate monitoring — the CM-SAF retrieval in international comparison[J]. Remote Sensing of Environment, 2012, 118(6) : 186–198.
- [3] RIDD M K, LIU J. A comparison of four algorithms for change detection in an urban environment[J]. Remote Sensing of Environment, 1998, 63(2) : 95–100.
- [4] YOUSIF O, BAN Y. Improving SAR-Based Urban Change Detection by Combining MAP-MRF Classifier and Nonlocal Means Similarity Weights[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(10) : 4288–4300.
- [5] BAN Y, YOUSIF O A. Multitemporal Spaceborne SAR Data for Urban Change Detection in China[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2012, 5(4) : 1087–1094.
- [6] XIAN G, YANG L, KLAVER J M. Urban Land-Cover Change Detection through Sub-Pixel Imperviousness Mapping Using Remotely Sensed Data[J]. Photogrammetric Engineering and Remote Sensing, 2015, 69(9) : 1003–1010.
- [7] BRUNNER D, BRUZZONE L, LEMOINE G. Change detection for earthquake damage assessment in built-up areas using very high resolution optical and SAR imagery[C] // Geoscience and Remote Sensing Symposium. 2010 : 3210–3213.
- [8] YANG H, DOU A, ZHANG W, et al. Study on extraction of earthquake damage information based on regional optimizing change detection from remote sensing image[C] // Geoscience and Remote Sensing Symposium. 2014 : 4272–4275.
- [9] ZHANG P, GONG M, SU L, et al. Change detection based on deep feature representation and mapping transformation for multi-spatial-resolution remote sensing images[J]. Isprs Journal of Photogrammetry and Remote Sensing, 2016, 116 : 24–41.
- [10] MATIKAINEN L, KARILA K, HYYPP J, et al. Object-based analysis of multispectral airborne laser scanner data for land cover classification and map updating[J]. Isprs Journal of Photogrammetry and Remote Sensing, 2017, 128 : 298–313.
- [11] RODRIGUES T W P, GUIMARAES U S. Change detection as support for monitoring the dynamic of land around reservoir[C] // Geoscience and Remote Sensing Symposium. 2014 : 4228–4231.

- [12] MOSER G, SERPICO S B. Generalized minimum-error thresholding for unsupervised change detection from SAR amplitude imagery[J]. IEEE Transactions on Geoscience and Remote Sensing, 2006, 44(10): 2972–2982.
- [13] GONG M, ZHOU Z, MA J. Change Detection in Synthetic Aperture Radar Images based on Image Fusion and Fuzzy Clustering[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2012, 21(4): 2141–2151.
- [14] GONG M, SU L, JIA M, et al. Fuzzy Clustering With a Modified MRF Energy Function for Change Detection in Synthetic Aperture Radar Images[J]. IEEE Transactions on Fuzzy Systems, 2014, 22(1): 98–109.
- [15] YOUSIF O, BAN Y. Improving Urban Change Detection From Multitemporal SAR Images Using PCA-NLM[J]. IEEE Transactions on Geoscience and Remote Sensing, 2013, 51(4): 2032–2041.
- [16] AUTHOR D L C, MAUSEL P, BRONDI ZIO E, et al. Change detection techniques[J]. International Journal of Remote Sensing, 2004, 25(12): 2365–2401.
- [17] HONG J, LEE, CHANG N. Urban Change Detection Between Heterogeneous Images Using the Edge Information[J]. Journal of the Korean Society of Surveying Geodesy Photogrammetry and Cartography, 2015, 33(4): 259–266.
- [18] MERCIER G, MOSER G, SERPICO S B. Conditional Copulas for Change Detection in Heterogeneous Remote Sensing Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2008, 46(5): 1428–1441.
- [19] PRENDES J, CHABERT M, PASCAL F, et al. A New Multivariate Statistical Model for Change Detection in Images Acquired by Homogeneous and Heterogeneous Sensors[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2015, 24(3): 799–812.
- [20] MUBEK K, MENZ G. Monitoring Land-Use Change in Nakuru (Kenya) Using Multi-Sensor Satellite Data[J]. Advances in Remote Sensing, 2012, 01(3).
- [21] JENSEN J R, RAMSEY E W, HEJR M, et al. Inland wetland change detection using aircraft MSS data.[J]. Photogrammetric Engineering and Remote Sensing, 1987, 53(5): 521–529.
- [22] GONG M, ZHANG P, SU L, et al. Coupled Dictionary Learning for Change Detection From Multi-source Data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(12): 7077–7091.
- [23] LIU J, GONG M, QIN K, et al. A Deep Convolutional Coupling Network for Change Detection Based on Heterogeneous Optical and Radar Images[J]. IEEE Transactions on Neural Networks and Learning Systems, 2016, PP(99): 1–15.
- [24] KOHONEN T. An introduction to neural computing[J]. Neural Networks, 1988, 1(1): 3–16.
- [25] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[C] // International Conference on Neural Information Processing Systems. 2015 :

- 91 – 99.
- [26] LIU J, GONG M, ZHAO J, et al. Difference representation learning using stacked restricted Boltzmann machines for change detection in SAR images[J]. *Soft Computing*, 2016, 20(12): 4645 – 4657.
  - [27] GONG M, ZHAO J, LIU J, et al. Change Detection in Synthetic Aperture Radar Images Based on Deep Neural Networks[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2017, 27(1): 125 – 138.
  - [28] ZHAO W, WANG Z, GONG M, et al. Discriminative Feature Learning for Unsupervised Change Detection in Heterogeneous Images Based on a Coupled Neural Network[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2017, PP(99): 1 – 15.
  - [29] HECHTNIELSEN. Theory of the backpropagation neural network[J]. *Neural Networks*, 1988, 1(1): 445 – 445.
  - [30] BRYSON A E, HO Y C, SIOURIS G M. Applied Optimal Control: Optimization, Estimation, and Control[J]. *Systems Man and Cybernetics IEEE Transactions on*, 1975, 9(6): 366 – 367.
  - [31] WERBOS P. Beyond Regression : New Tools for Prediction and Analysis in the Behavioral Science[J]. Ph.d.dissertation Harvard University, 1974, 29(18): 65 – 78.
  - [32] PARKER D B. Optimal Algorithms for Adaptive Networks: Second Order Back Propagation, Second Order Direct Propagation, and Second Order Hebbian Learning[C] // *IEEE International Conference Onneural Networks*. 1987.
  - [33] RUMELHART D E. Learning internal representations by error propagarion[J]. *Parallel Distributed Processing Explorations in the Microstructures of Cognition*, 1986.
  - [34] 周志华. 机器学习: = Machine learning[M]. 北京: 清华大学出版社, 2016: 97 – 107.
  - [35] ROSIN P L, IOANNIDIS E. Evaluation of global image thresholding for change detection[J]. *Pattern Recognition Letters*, 2003, 24(14): 2345 – 2356.
  - [36] BRENNAN R L, PREDIGER D J. Coefficient Kappa: Some Uses, Misuses, and Alternatives[J]. *Educational and Psychological Measurement*, 1981, 41(3): 687 – 699.
  - [37] SMOLENSKY P. Information processing in dynamical systems: foundations of harmony theory[C] // *Parallel Distributed Processing*. Cambridge, MA, USA: MIT Press, 1986: 194 – 281.
  - [38] HINTON G E, OSINDERO S, TEH Y W. A Fast Learning Algorithm for Deep Belief Nets[J]. *Neural Computation*, 2014, 18(7): 1527 – 1554.
  - [39] NAIR V, HINTON G E. Rectified linear units improve restricted boltzmann machines[C] // *International Conference on International Conference on Machine Learning*. 2010: 807 – 814.
  - [40] LAROCHELLE H, BENGIO Y. Classification using discriminative restricted Boltzmann machines[C] // *International Conference*. 2008: 536 – 543.

- [41] SALAKHUTDINOV R, MNH A, HINTON G. Restricted Boltzmann machines for collaborative filtering[C] // International Conference on Machine Learning. 2007 : 791 – 798.
- [42] COATES A, NG A Y, LEE H. An Analysis of Single-Layer Networks in Unsupervised Feature Learning[J]. Journal of Machine Learning Research, 1991, 15 : 215 – 223.
- [43] HINTON G E. A Practical Guide to Training Restricted Boltzmann Machines[J]. Momentum, 2012, 9(1) : 599 – 619.
- [44] WANG Q, LIN J, YUAN Y. Salient Band Selection for Hyperspectral Image Classification via Manifold Ranking.[J]. IEEE Transactions on Neural Networks and Learning Systems, 2017, 27(6) : 1279 – 1289.
- [45] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C] // Computer Vision and Pattern Recognition. 2016 : 779 – 788.
- [46] DAI J, LI Y, HE K, et al. R-FCN: Object Detection via Region-based Fully Convolutional Networks[C] // International Conference on Neural Information Processing Systems. 2016 : 379 – 387.
- [47] KRINIDIS S, CHATZIS V. A Robust Fuzzy Local Information C-Means Clustering Algorithm[J]. IEEE Transactions on Image Processing, 2010, 19(5) : 1328.
- [48] SZILAGYI L, BENYO Z, SZILAGYI S M, et al. MR brain image segmentation using an enhanced fuzzy C-means algorithm[C] // Engineering in Medicine and Biology Society, 2003. Proceedings of the International Conference of the IEEE. 2003 : 724 – 726 Vol.1.
- [49] GONG M, LIANG Y, SHI J, et al. Fuzzy C-means clustering with local information and kernel metric for image segmentation[J]. IEEE Transactions on Image Processing, 2013, 22(2) : 573 – 584.
- [50] CAI W, CHEN S, ZHANG D. Fast and robust fuzzy c -means clustering algorithms incorporating local information for image segmentation[J]. Pattern Recognition, 2007, 40(3) : 825 – 838.
- [51] CHEN S, ZHANG D. Robust image segmentation using FCM with spatial constraints based on new kernel-induced distance measure[J]. Systems Man and Cybernetics Part B Cybernetics IEEE Transactions on, 2004, 34(4) : 1907.
- [52] BOVOLO F, BRUZZONE L. A detail-preserving scale-driven approach to change detection in multitemporal SAR images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2005, 43(12) : 2963 – 2972.
- [53] RIGNOT E J M, VAN ZYL J J. Change detection techniques for ERS-1 SAR data[J]. Geoscience and Remote Sensing IEEE Transactions on, 1993, 31(4) : 896 – 906.
- [54] AHMED M N, YAMANY S M, MOHAMED N, et al. A modified fuzzy C-means algorithm for bias field estimation and segmentation of MRI data.[J]. IEEE Transactions on Medical Imaging, 2002, 21(3) : 193 – 199.

## 致谢

时光荏苒，我的硕士生涯已至谢幕时刻。这一段路程及漫长又短暂，途中虽充满了酸甜苦辣，但更有收获和成长。感谢陪我度过研究生时光的每位尊敬的老师和亲爱的同学，正是你们的指导与帮助，我才能顺利完成学业。

感谢张青富教授，您对科研严谨端正的态度、对工作兢兢业业的精神以及对事业孜孜不倦的追求深深感染和影响了我，使我受益终身。

感谢公茂果教授。在研究生期间，老师在学术上对我给予了耐心的指导和帮助。平时每周例会上，老师都会根据我们每个人的研究内容给出针对性的建议。在毕设论文的写作中，从选题直至最终完成，无不渗透着老师的心血。公老师渊博的专业知识，精益求精的工作作风，严谨的治学态度，诲人不倦的高尚师德，朴实无华、平易近人的人格魅力对我影响深远。值此论文完稿之际，向老师致以衷心的感谢和崇高的敬意。

感谢OMEGA小组中的所有成员，是你们营造的良好的学术氛围和严谨的科研态度使我受益匪浅。感谢图像组的博士师兄们，感谢你们在学术上给予的帮助，是你们细心与无私的指导，让我对图像变化检测有了深入的了解，使我在学术上有了快速的进步。感谢我的舍友们，是你们让我拥有了一段快乐而充实的研究生生活。

特别的，我要感谢我的父母。感谢你们对我学业的支持，让我没有顾虑地专注于学习知识；感谢你们对于生活宽容而向上的态度，使我积极乐观并保持善良。

最后，我要向百忙之中参与审阅、评阅论文的各位老师，向参与文答辩的各位老师表示由衷的感谢！



## 作者简介

### 1. 基本情况

王志锐，女，河北邢台人，1990年3月出生，西安电子科技大学 电子工程 学院 电路与系统 专业 2015 级硕士研究生。

### 2. 教育背景

2011.09～2015.07，陕西师范大学，本科，专业：电子信息科学与技术

2015.09～，西安电子科技大学，硕士研究生，专业：电路与系统

### 3. 攻读硕士学位期间的研究成果

#### 3.1 发表学术论文

- [1] Wei Zhao, Zhirui Wang, Maoguo Gong. Discriminative Feature Learning for Unsupervised Change Detection in Heterogeneous Images Based on a Coupled Neural Network[J]. IEEE Transaction on Geoscience and Remote Sensing, 2017, 55(12): 7066 - 7080.

#### 3.2 申请（授权）专利

- [1] 公茂果, 马晶晶, 王志锐等. 一种基于无监督深度神经网络的异质图像变化检测方法: 专利号[201710022541.8]. 2017年6月20日.

